ISCAS 中国科学院软件研究所 Institute of Software Chinese Academy of Sciences
智能软件研究中心 Intelligent Software Research Center

MLIR 的简介、实践、思考

张洪滨

2021.10.25

目录

1. MLIR 简介 – 深度学习框架的发展 | 什么是MLIR
2. MLIR 实践 – MLIR 社区工作 | buddy-mlir
3. MLIR 思考 – 基于 MLIR 的深度学习框架

1. MLIR 简介 – 深度学习框架的发展 | 什么是MLIR

MLIR 简介 – 深度学习框架的发展

多种语言绑定

C/C++ 接口

TensorFlow后端部分

- 运行时部分
- 框架部分
- 计算图部分
- 图优化部分
- 计算核函数部分
- 计算节点部分

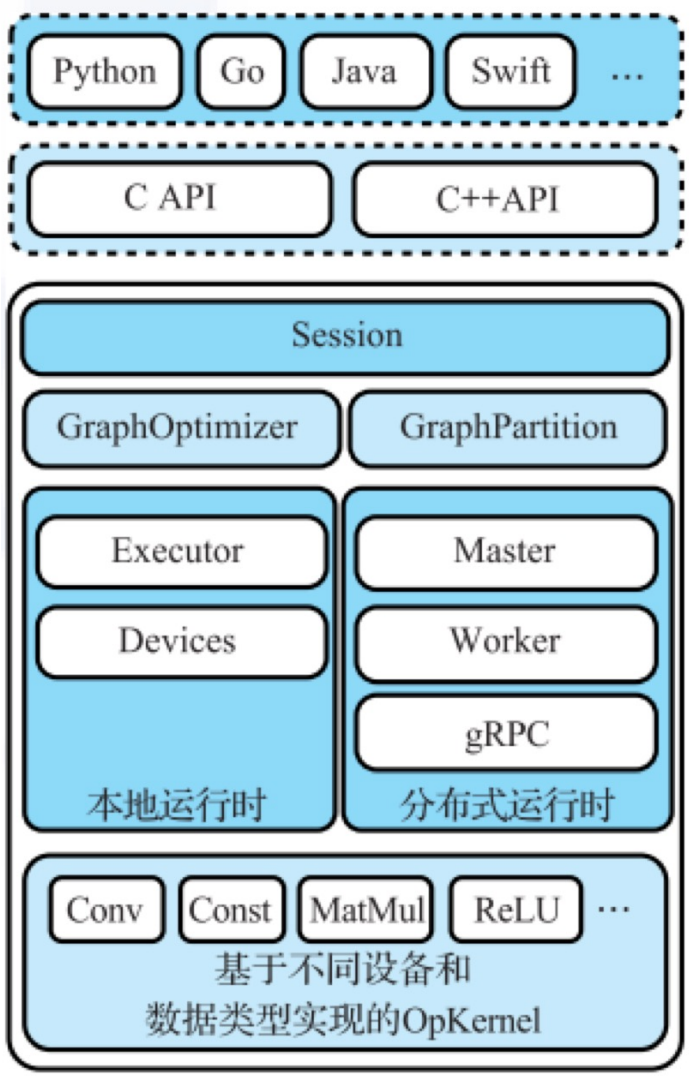

TensorFlow 整体架构图

参考自：《智能计算系统》

MLIR 简介 – 深度学习框架的发展

多种语言绑定

C/C++ 接口

TensorFlow后端部分

- 运行时部分
- 框架部分
- 计算图部分
- 图优化部分
- 计算核函数部分
- 计算节点部分

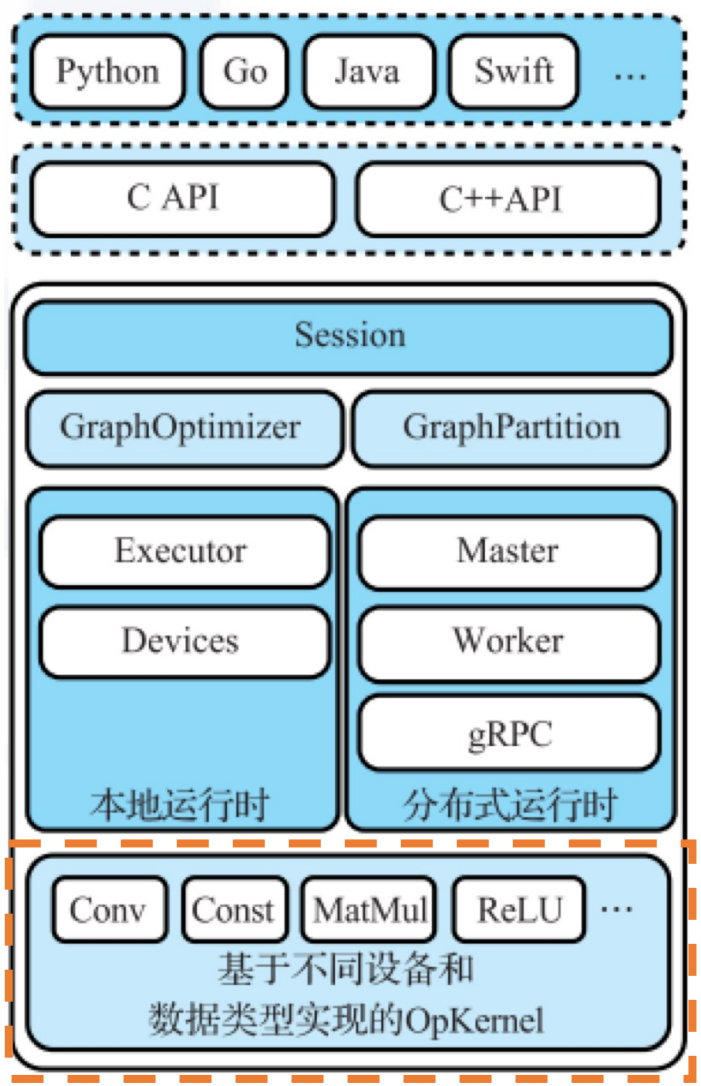

TensorFlow 整体架构图

不同的底层硬件
OpKernel有不同的实现

- CPU
- GPU
- 深度学习处理器

参考自：《智能计算系统》

MLIR 简介 – 深度学习框架的发展

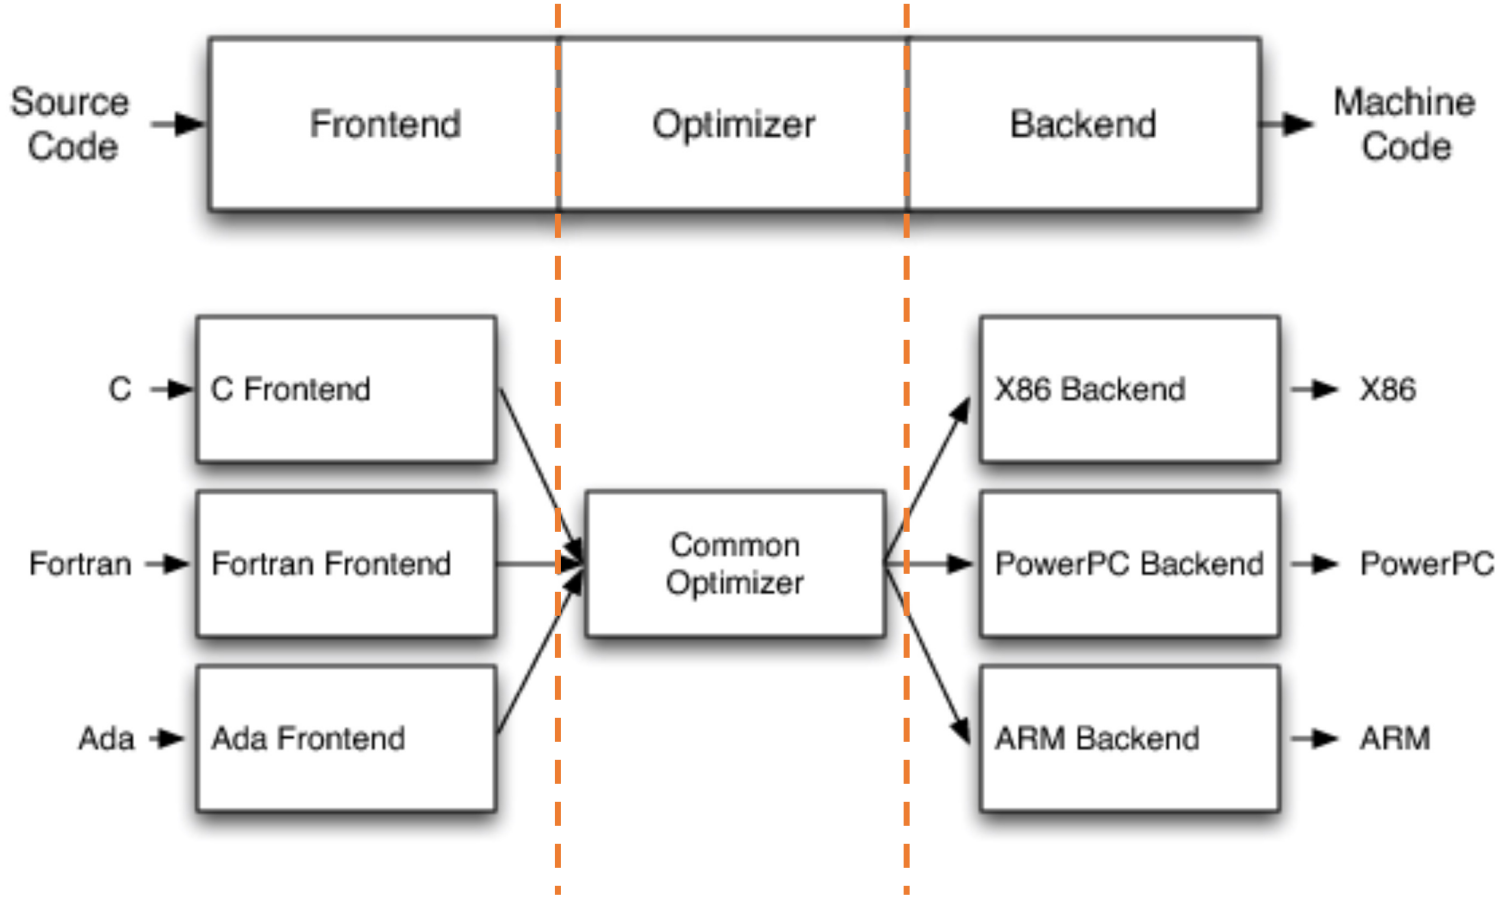

参考自：LLVM, Chris Lattner, http://aosabook.org/en/llvm.html

MLIR 简介 – 深度学习框架的发展

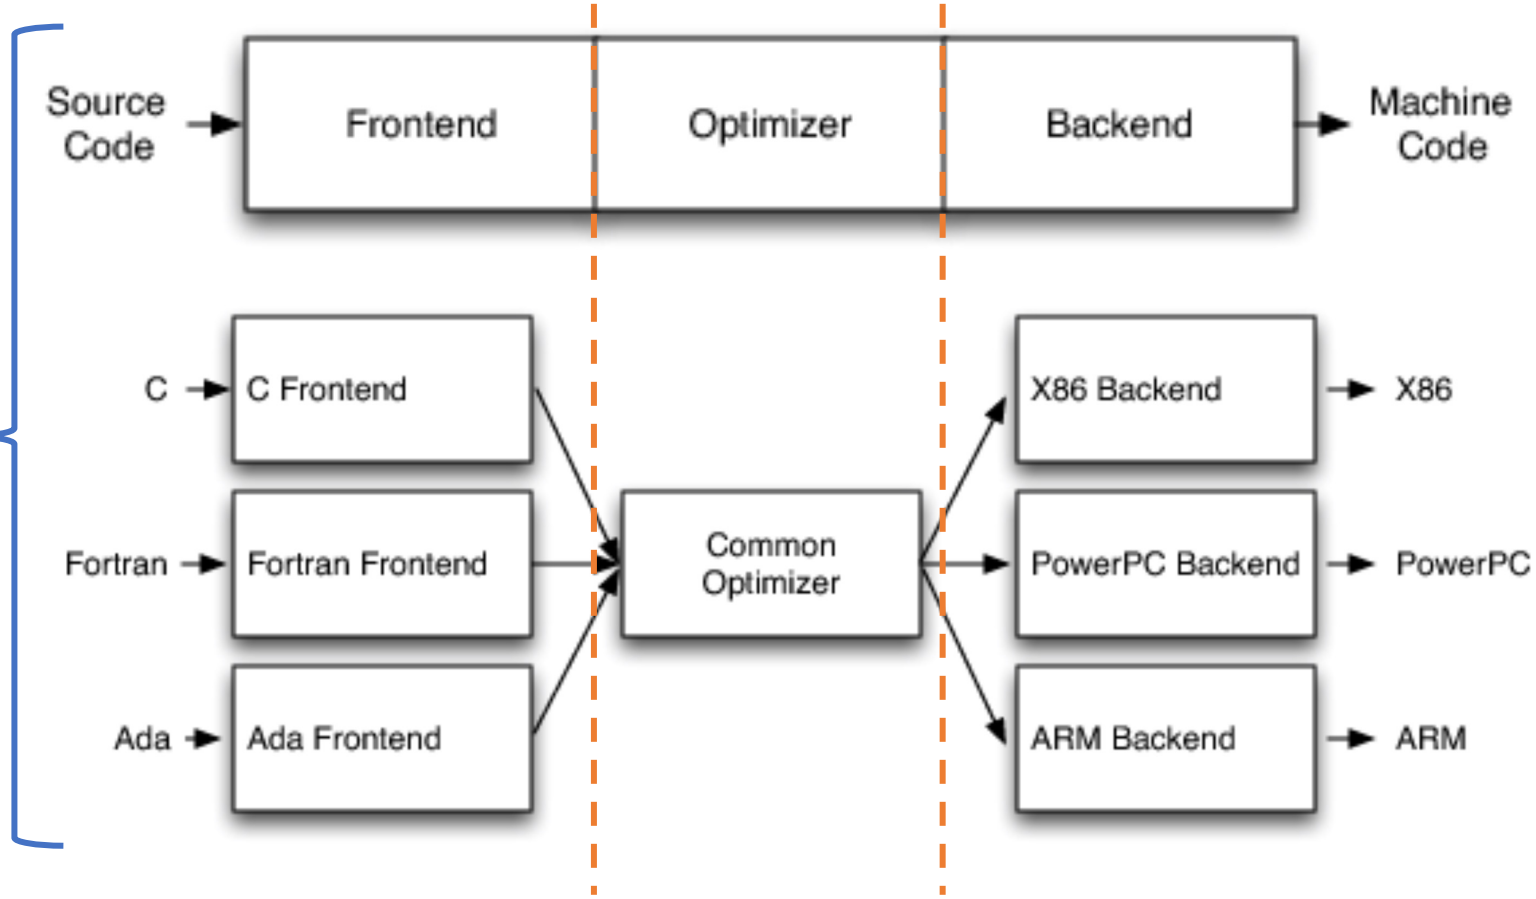

前端

- 词法语法分析
- 构造抽象语法树
- 语义检查
- IR转换

参考自：LLVM, Chris Lattner, http://aosabook.org/en/llvm.html

MLIR 简介 – 深度学习框架的发展

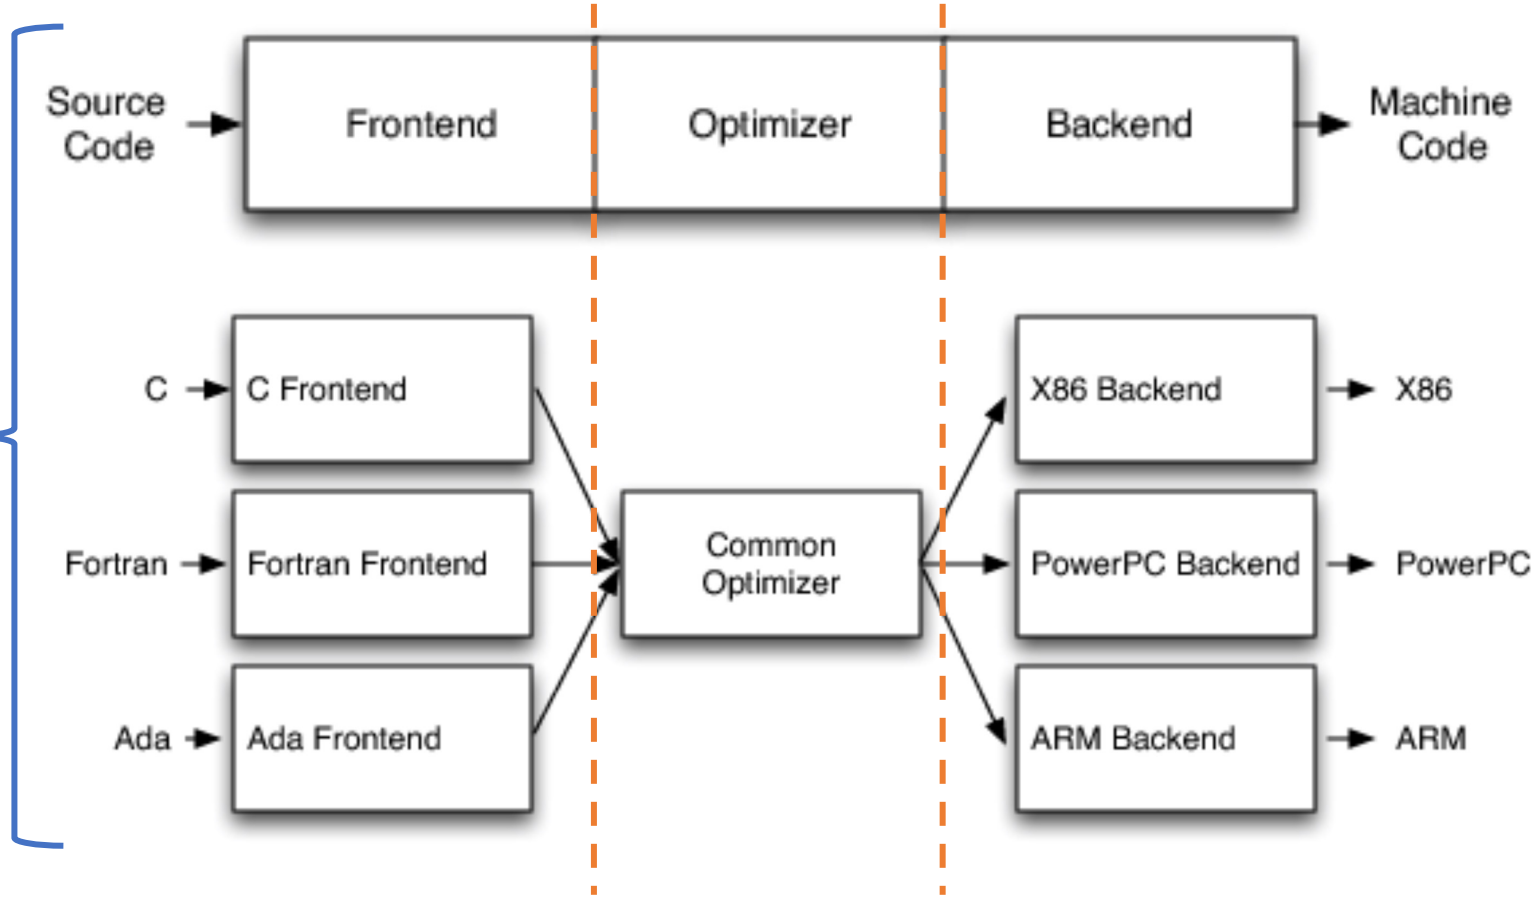

前端

- 词法语法分析
- 构造抽象语法树
- 语义检查
- IR转换

中端/优化器

进行各种 IR 层级的优化

参考自：LLVM, Chris Lattner, http://aosabook.org/en/llvm.html

MLIR 简介 – 深度学习框架的发展

前端

- 词法语法分析
- 构造抽象语法树
- 语义检查
- IR转换

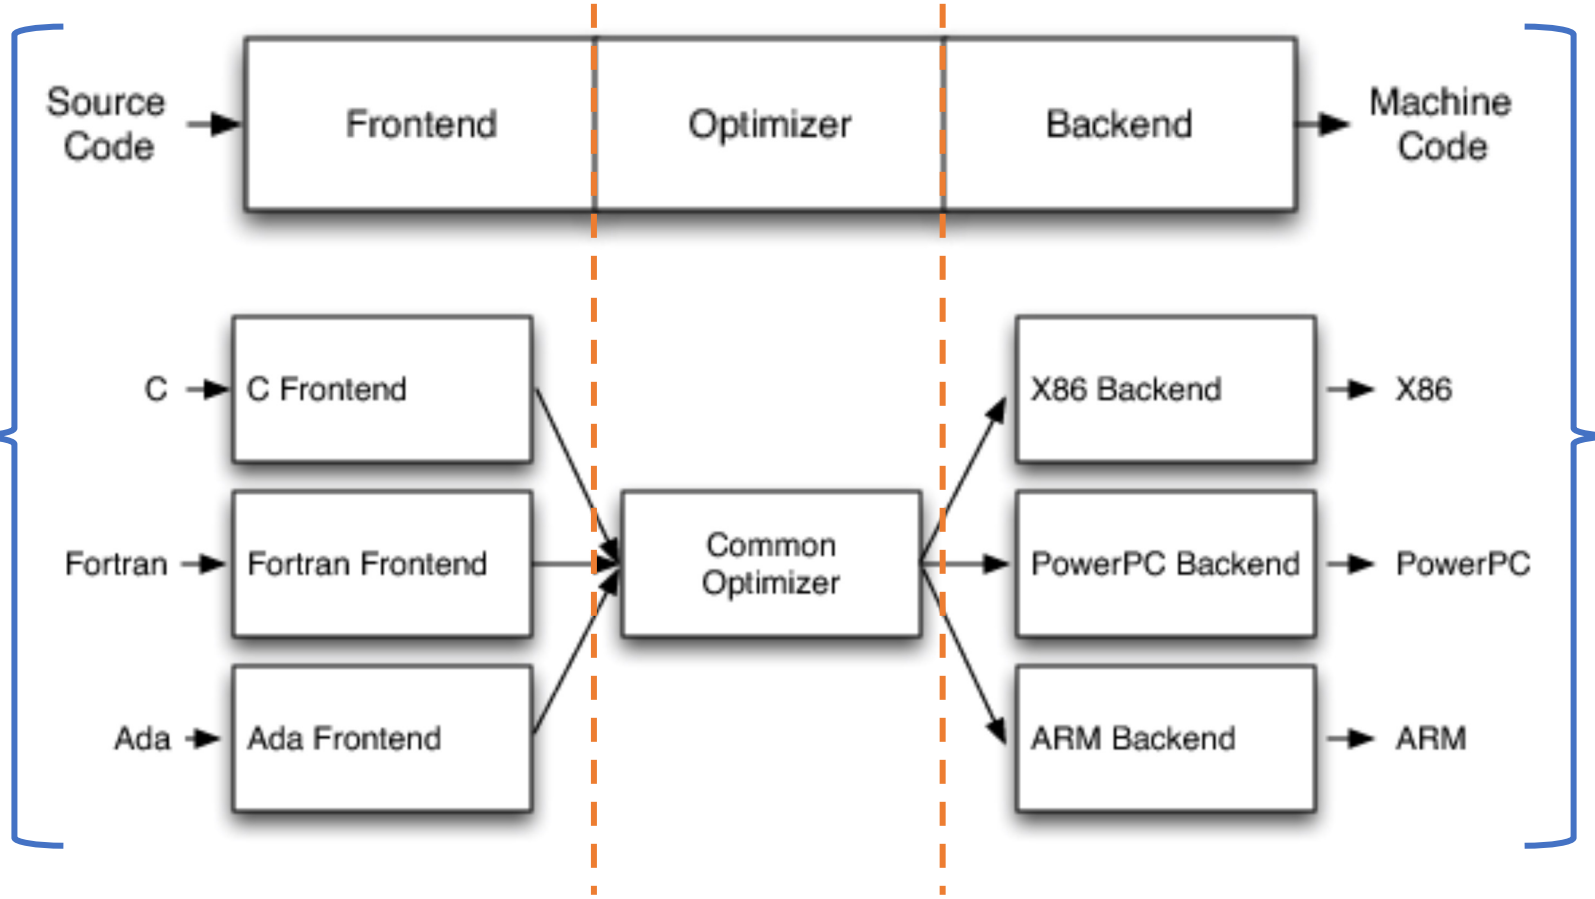

后端

- 指令选择
- 寄存器分配
- 代码生成

中端/优化器

进行各种 IR 层级的优化

参考自：LLVM, Chris Lattner, http://aosabook.org/en/llvm.html

MLIR 简介 – 深度学习框架的发展

多种语言绑定

C/C++ 接口

TensorFlow后端部分

- 运行时部分
- 框架部分
- 计算图部分
- 图优化部分
- 计算核函数部分
- 计算节点部分

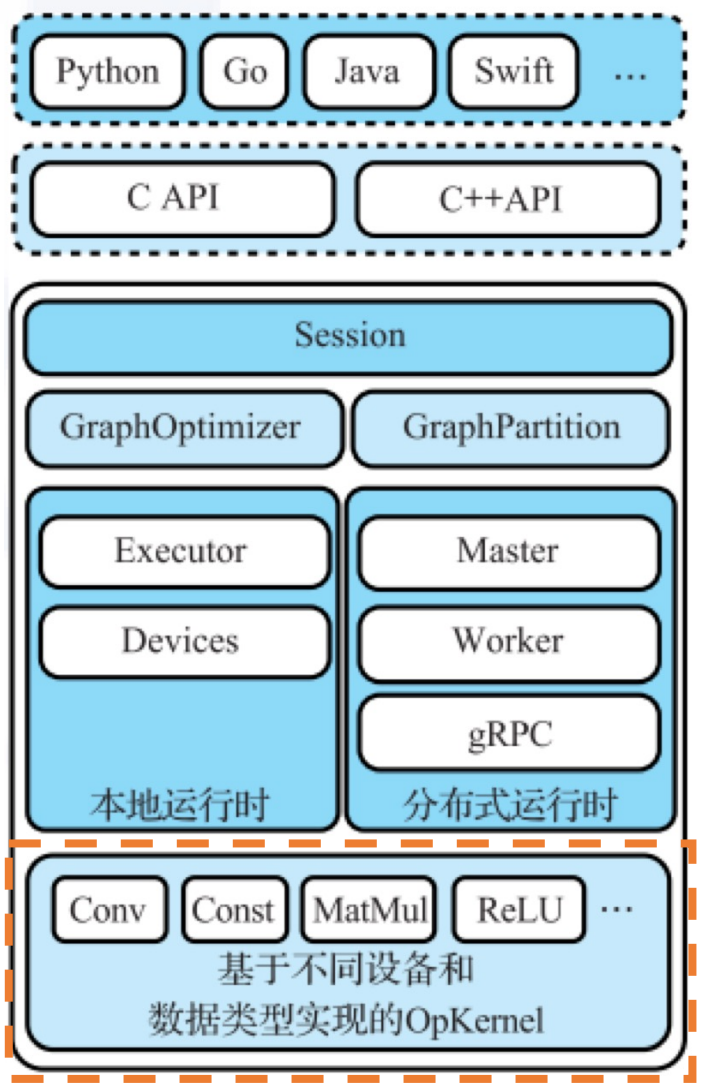

TensorFlow 整体架构图

不同的底层硬件
OpKernel有不同的实现

- CPU
- GPU
- 深度学习处理器

参考自：《智能计算系统》

MLIR 简介 – 深度学习框架的发展

多种语言绑定

C/C++ 接口

TensorFlow后端部分

- 运行时部分
- 框架部分
- 计算图部分
- 图优化部分
- 计算核函数部分
- 计算节点部分

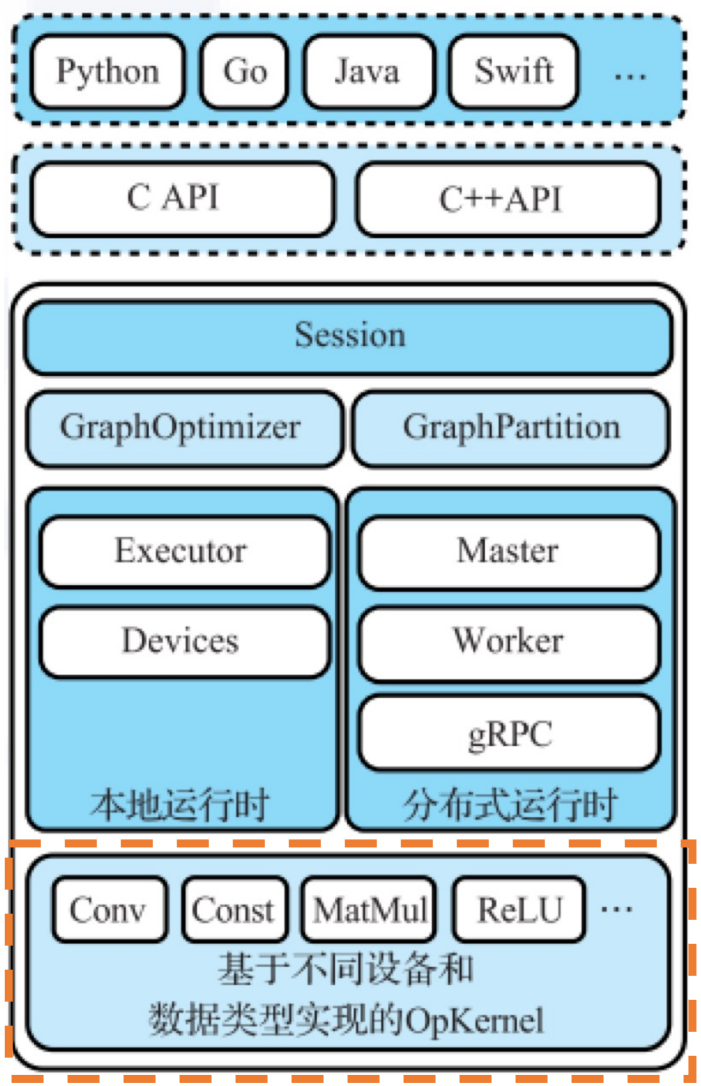

TensorFlow 整体架构图

不同的底层硬件
OpKernel有不同的实现
- CPU
- GPU
- 深度学习处理器

XLA 线性代数计算优化机制
引入中间表示层（IR）和编译器

参考自：《智能计算系统》

MLIR 简介 – 深度学习框架的发展

通过编译技术优化机器学习平台性能

- 加速数据流图执行
- 提升内存使用效率
- 降低自定义操作依赖
- 减小移动应用内存占用
- 增加平台可移植性

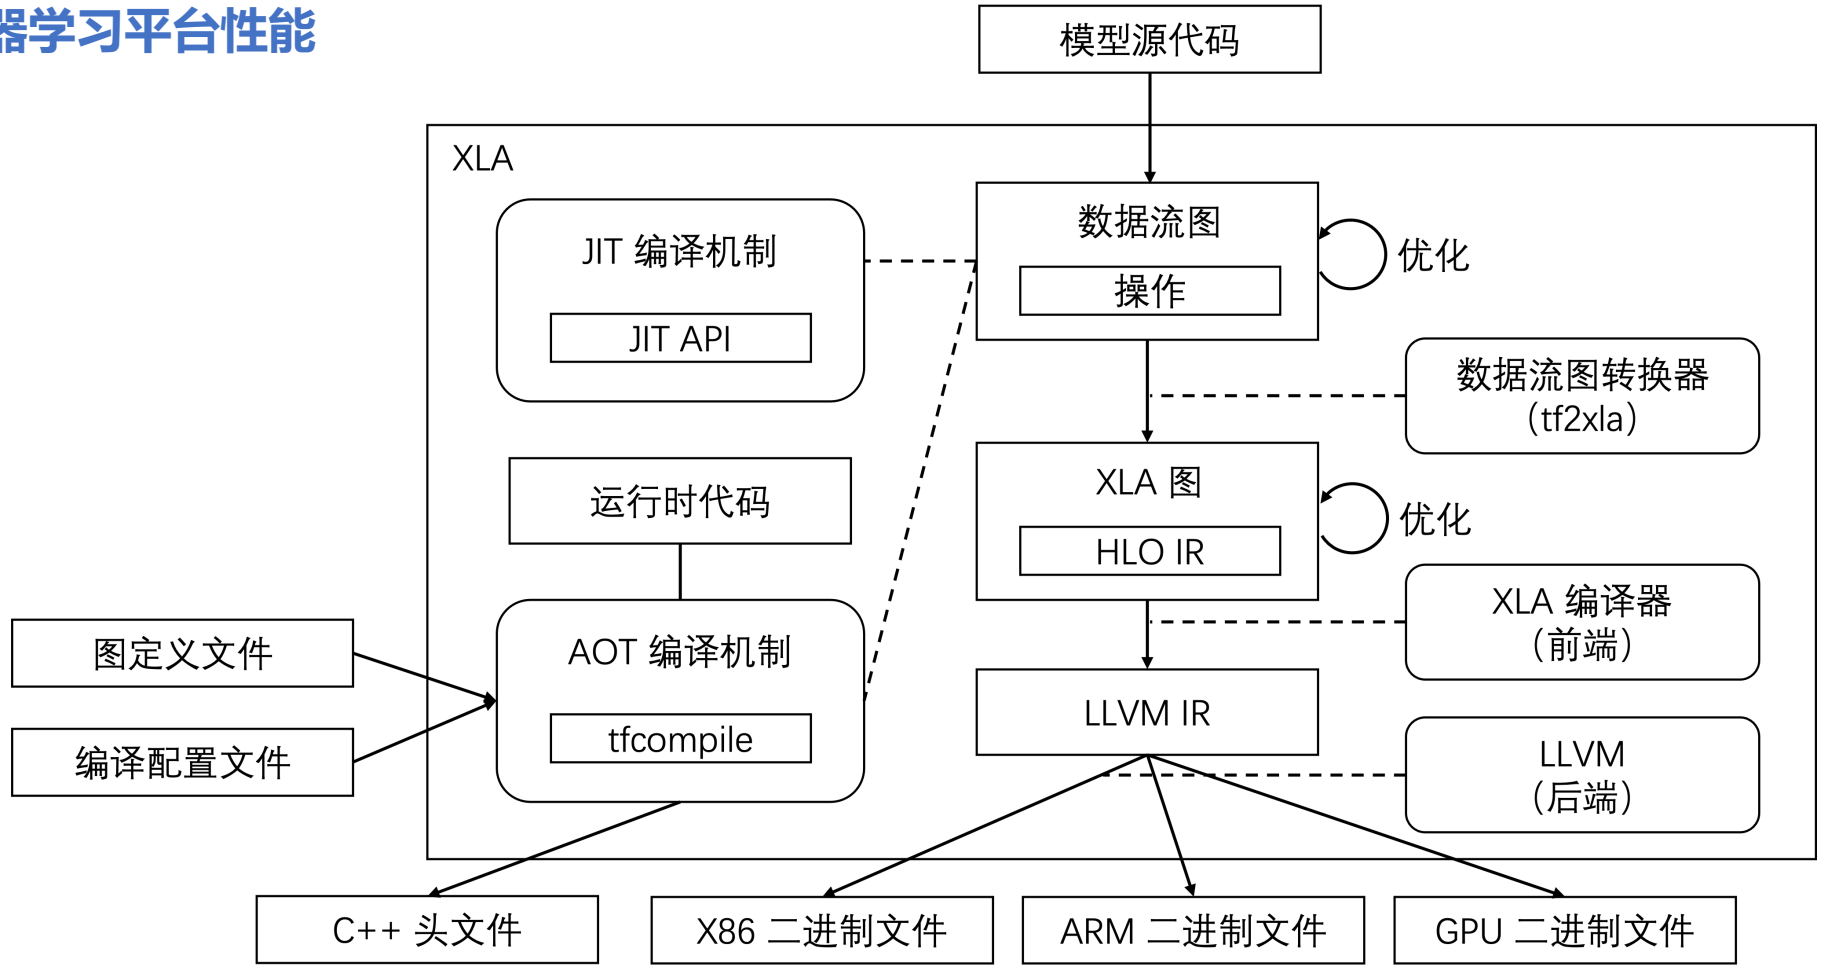

参考自：《深入理解 TensorFlow》

MLIR 简介 – 深度学习框架的发展

通过编译技术优化机器学习平台性能

- 加速数据流图执行
- 提升内存使用效率
- 降低自定义操作依赖
- 减小移动应用内存占用
- 增加平台可移植性

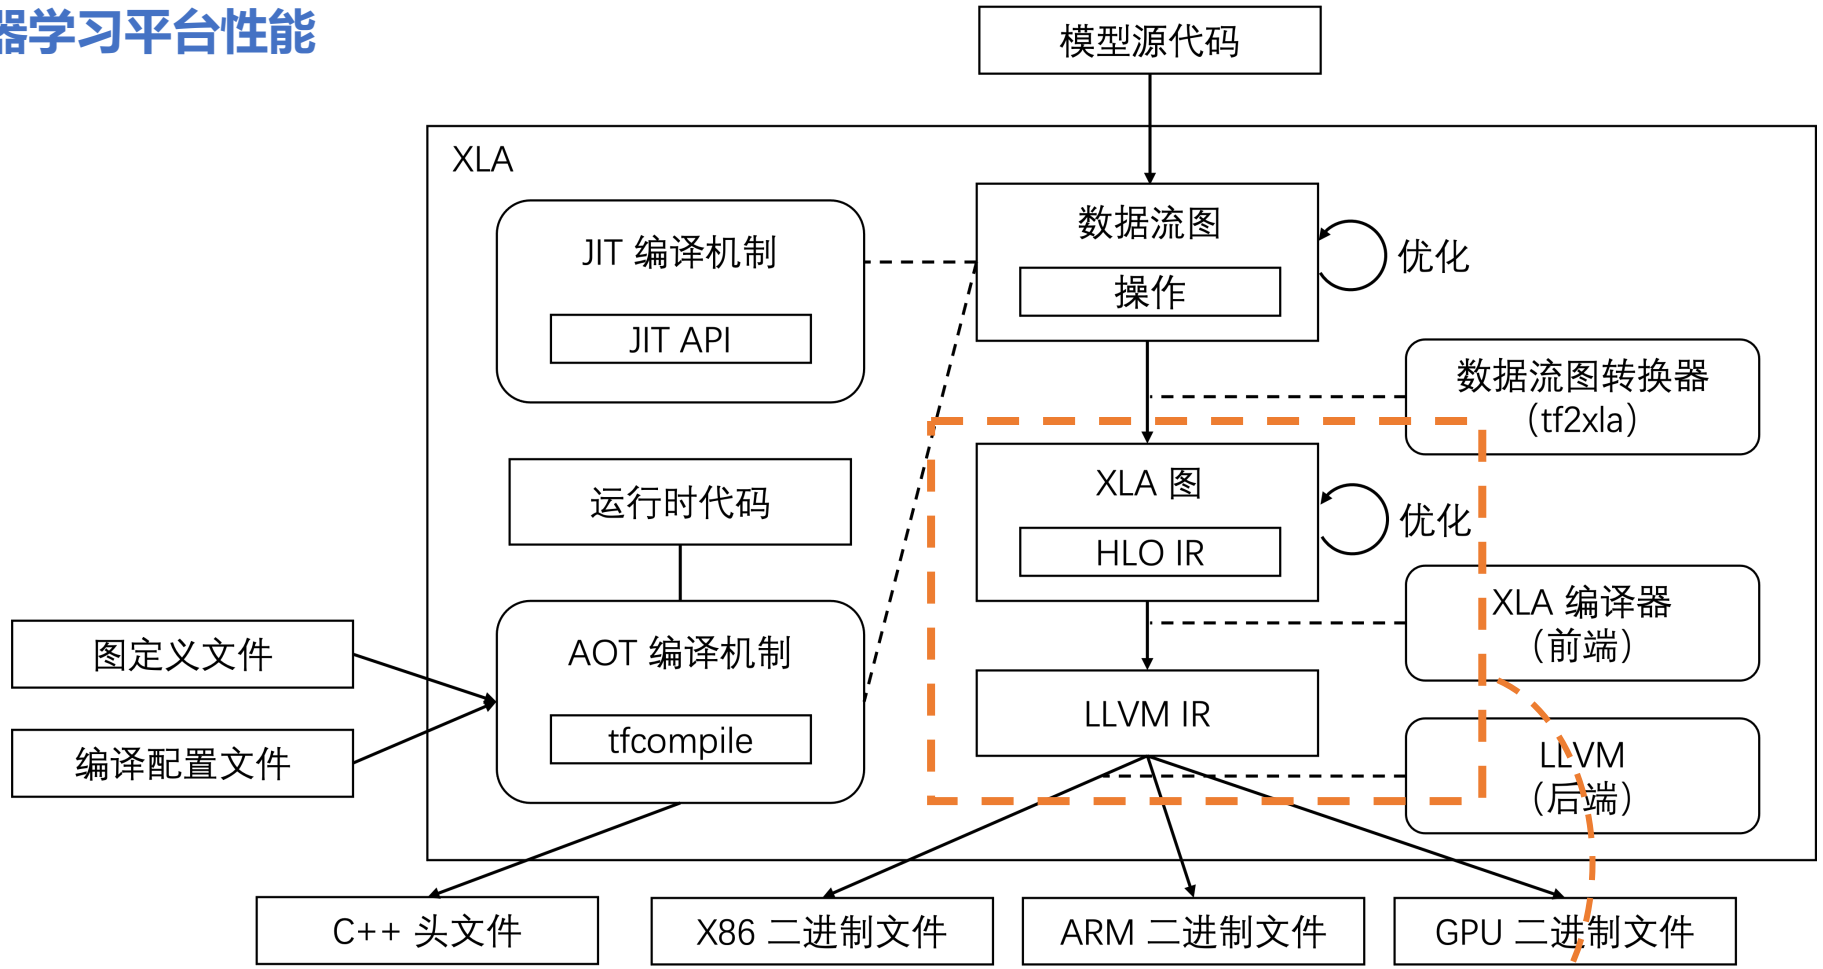

HLO的引入将核函数开发时的前后端代码解耦，增强可移植性

参考自：《深入理解 TensorFlow》

MLIR 简介 – 深度学习框架的发展

通过编译技术优化机器学习平台性能

- 加速数据流图执行
- 提升内存使用效率
- 降低自定义操作依赖
- 减小移动应用内存占用
- 增加平台可移植性

JIT 用于运行时创建执行数据流图操作的二进制代码
面向异构设备进行性能优化

AOT 在运行前创建并集成了
模型和运行时的二进制代码
适用于移动端的推理过程的性能优化

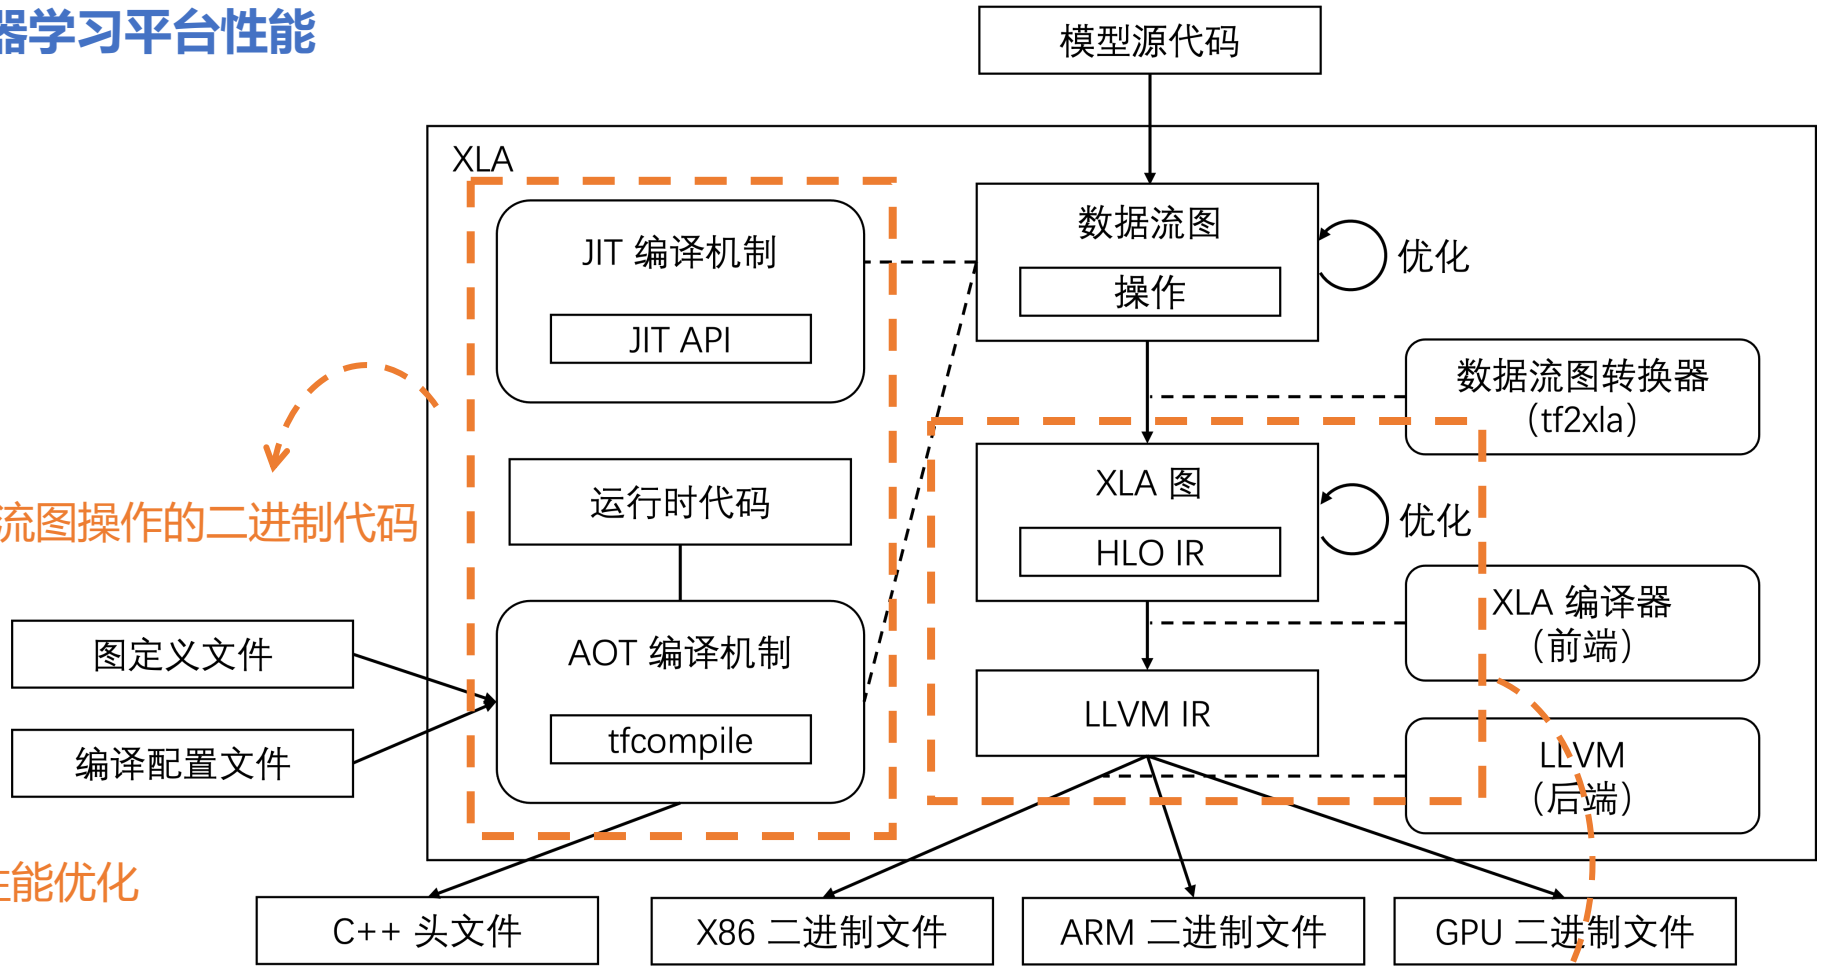

HLO的引入将核函数开发时的前后端代码解耦，增强可移植性

参考自：《深入理解 TensorFlow》

MLIR 简介 – TensorFlow执行方式

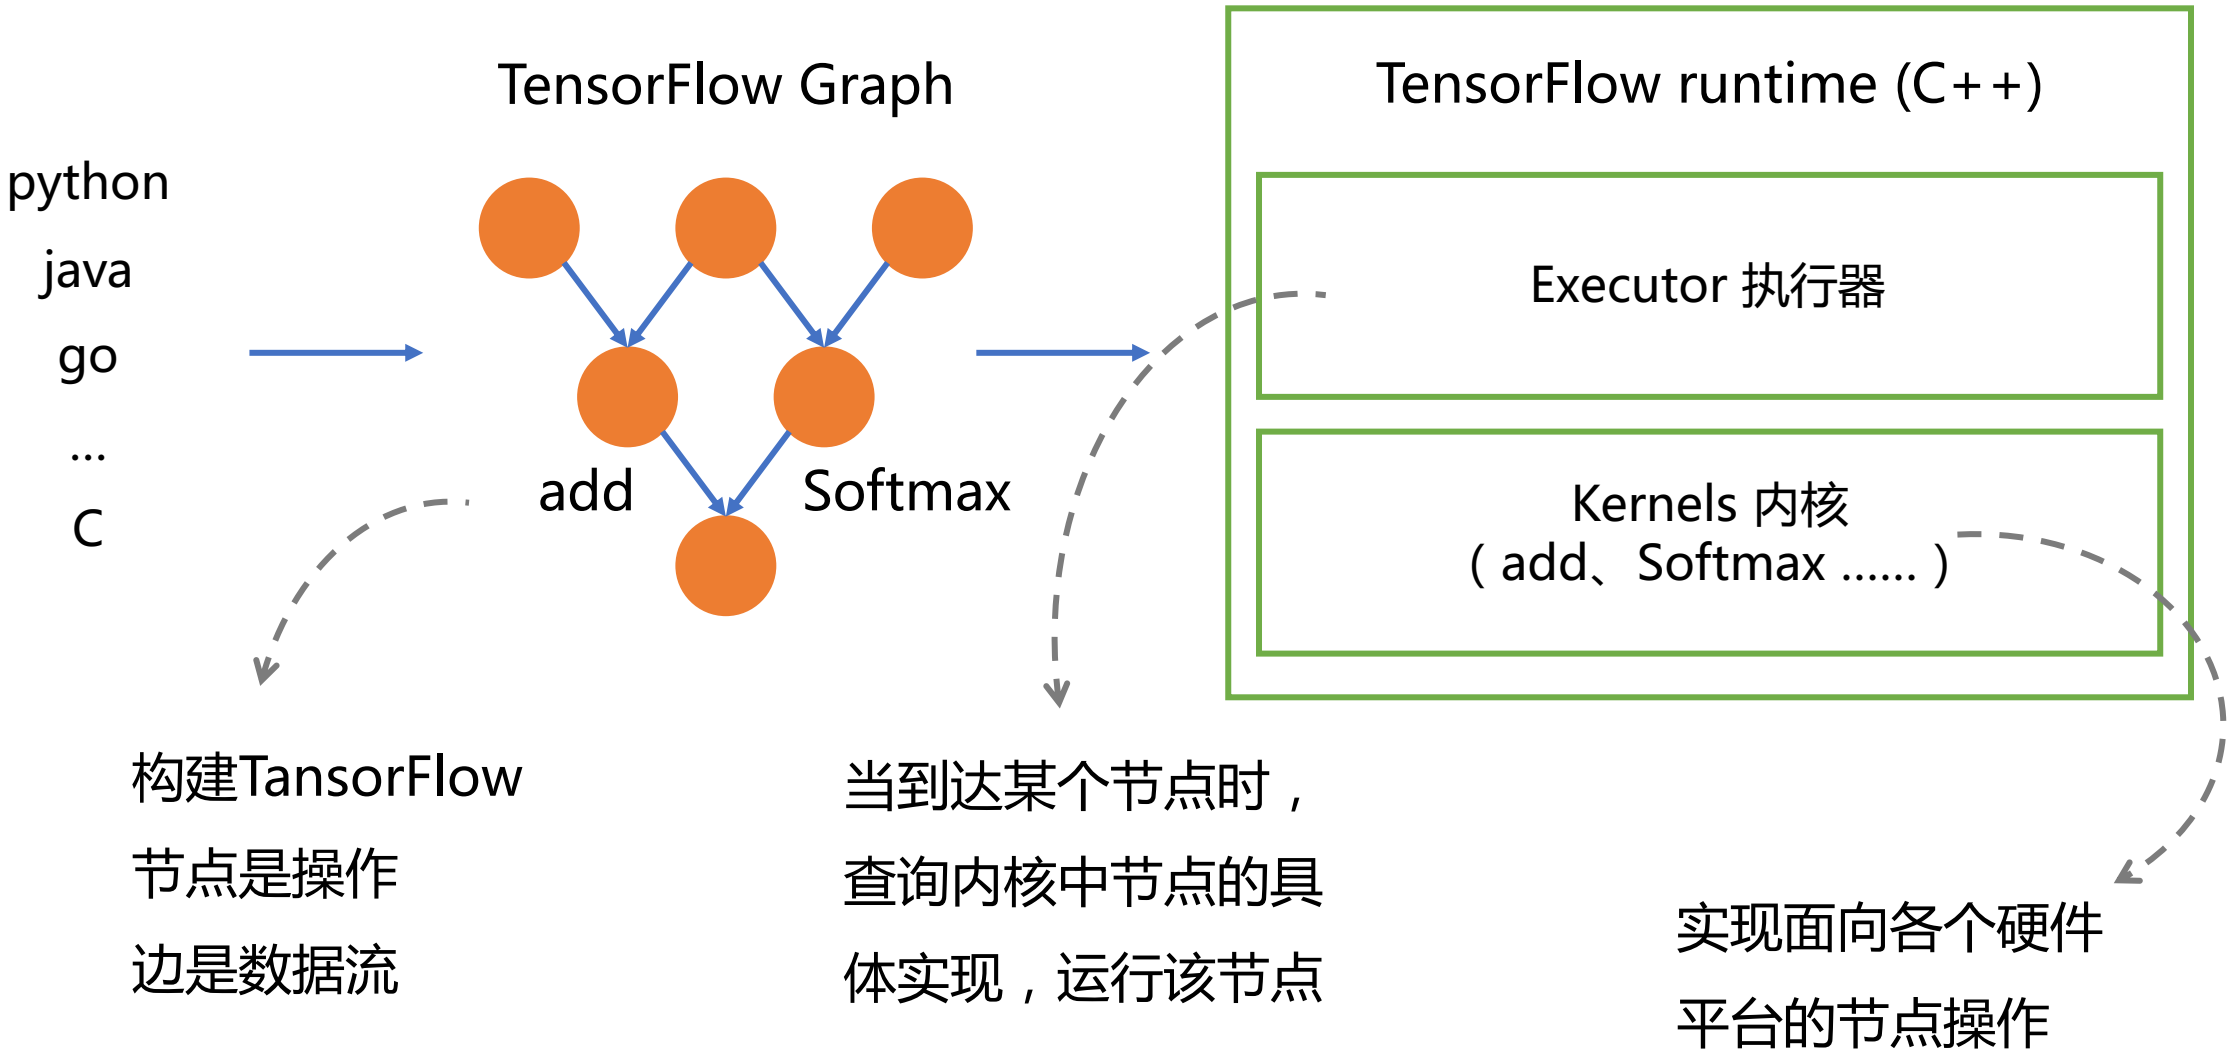

参考自：XLA: TensorFlow, Compiled!, TensorFlow Dev Summit 2017.

MLIR 简介 – 使用XLA加速TensorFlow

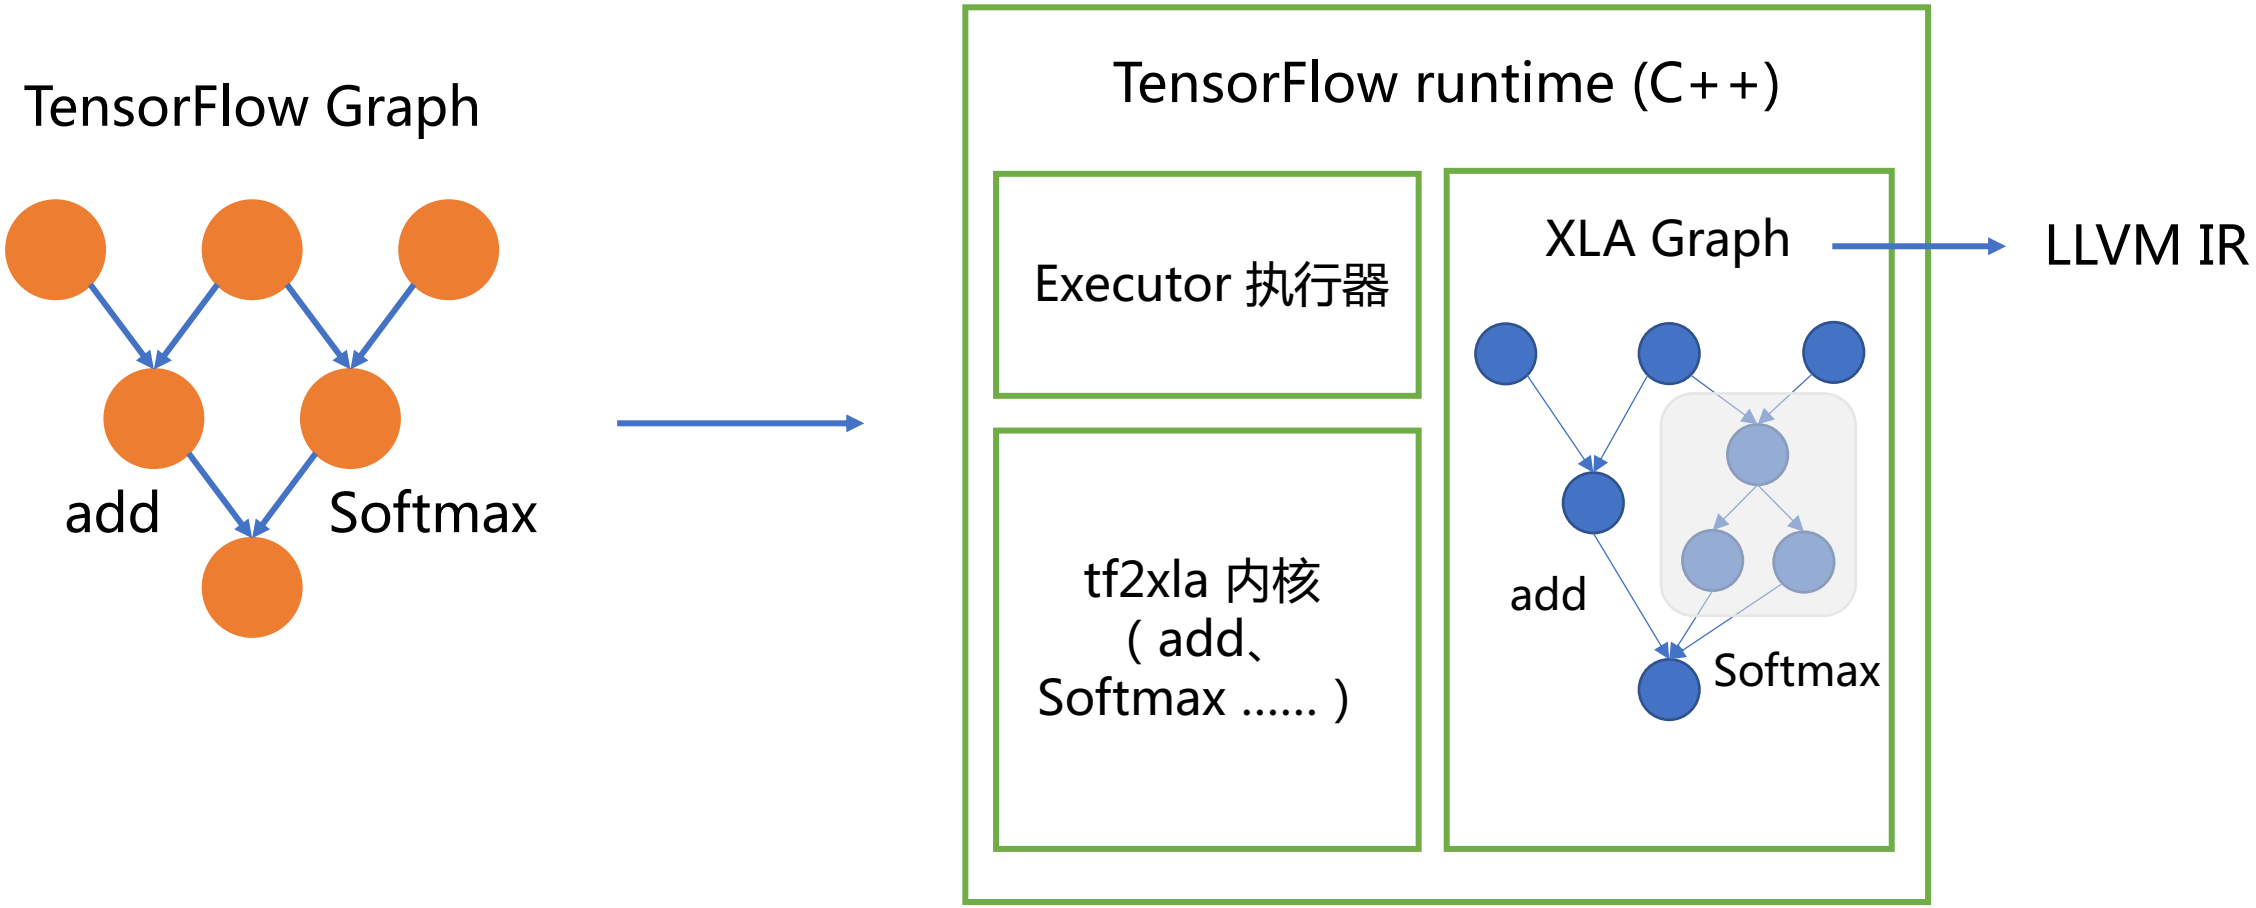

参考自：XLA: TensorFlow, Compiled!, TensorFlow Dev Summit 2017.

MLIR 简介 – 存在什么问题

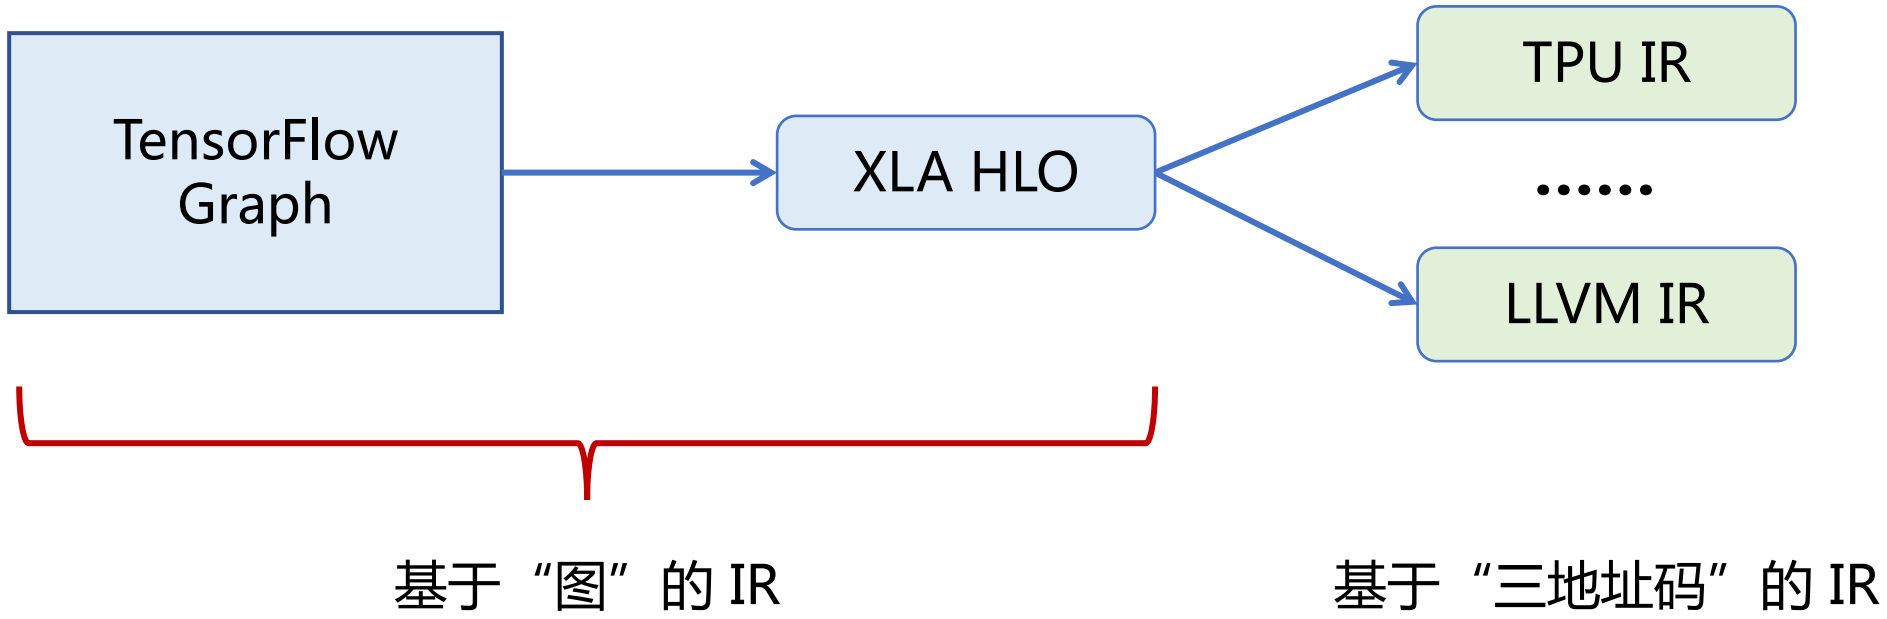

- 组合爆炸，很多组件无法重用
- 各个层次内部优化无法迁移
- 从XLA HLO到LLVM IR跨度太大，实现开销大

MLIR 简介 – 什么是MLIR

不是Machine Learning，但为Machine Learning而生

MLIR (Multi-Level Intermediate Representation)

The MLIR project is a novel approach to building reusable and extensible compiler infrastructure. MLIR aims to address software fragmentation, improve compilation for heterogeneous hardware, significantly reduce the cost of building domain specific compilers, and aid in connecting existing compilers together.

一个可重用、可扩展的开源编译基础框架

- 处理软件的碎片化
- 为面向异构硬件的编译提供支持
- 为领域专用编译器的开发减少开销
- 连接已有的各种编译器

MLIR 简介 – MLIR如何解决问题

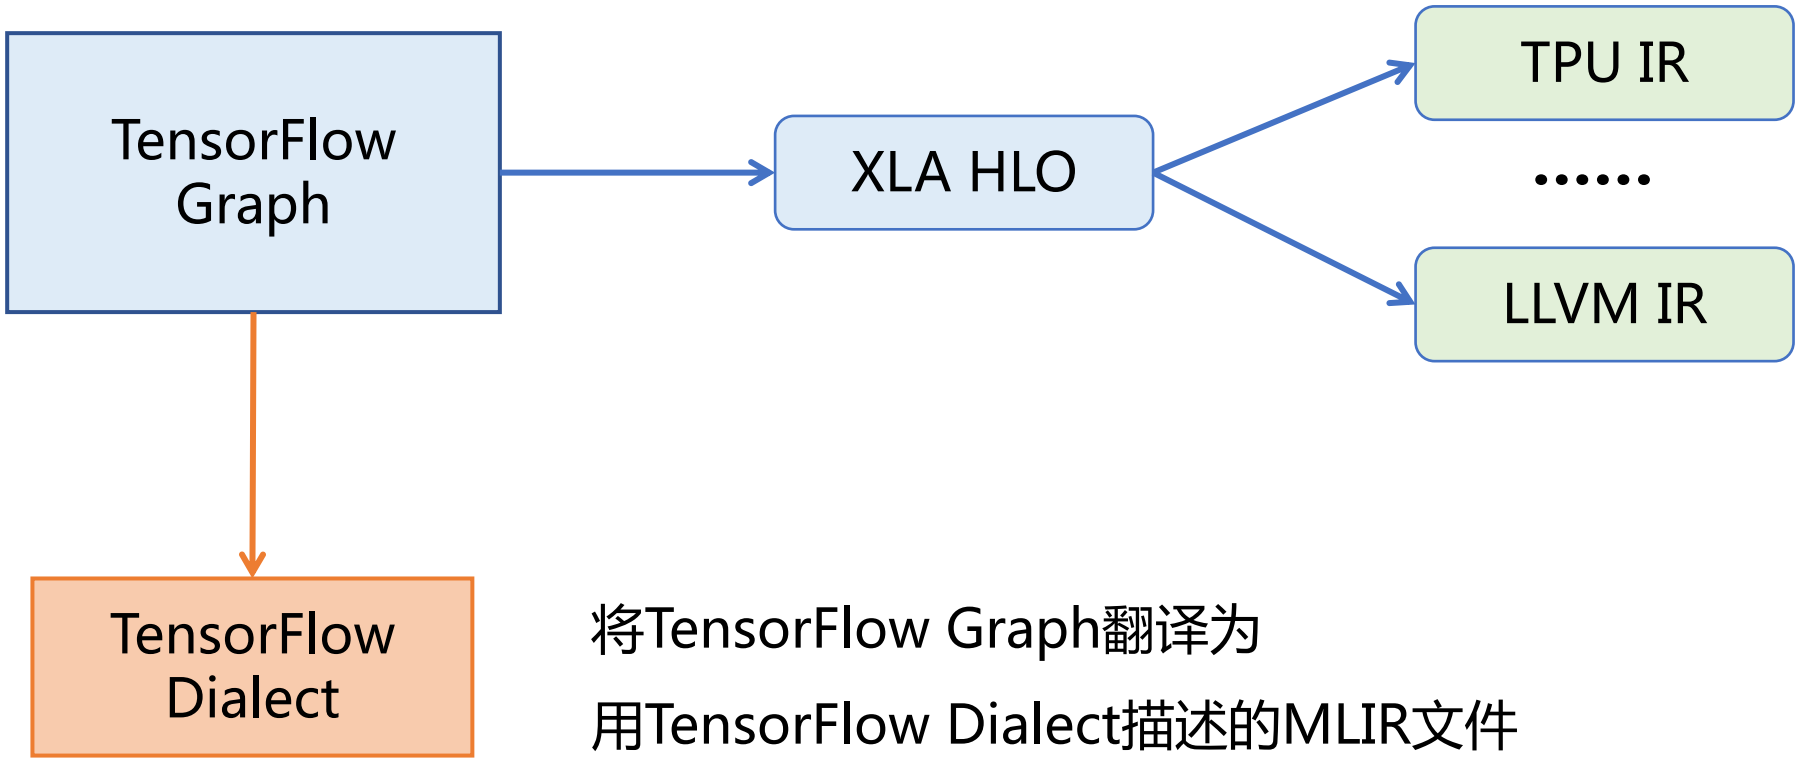

将TensorFlow Graph翻译为

用TensorFlow Dialect描述的MLIR文件

- 组合爆炸，很多组件无法重用
- 各个层次内部优化无法迁移
- 从XLA HLO到LLVM IR跨度太大，实现开销大

MLIR 简介 – MLIR如何解决问题

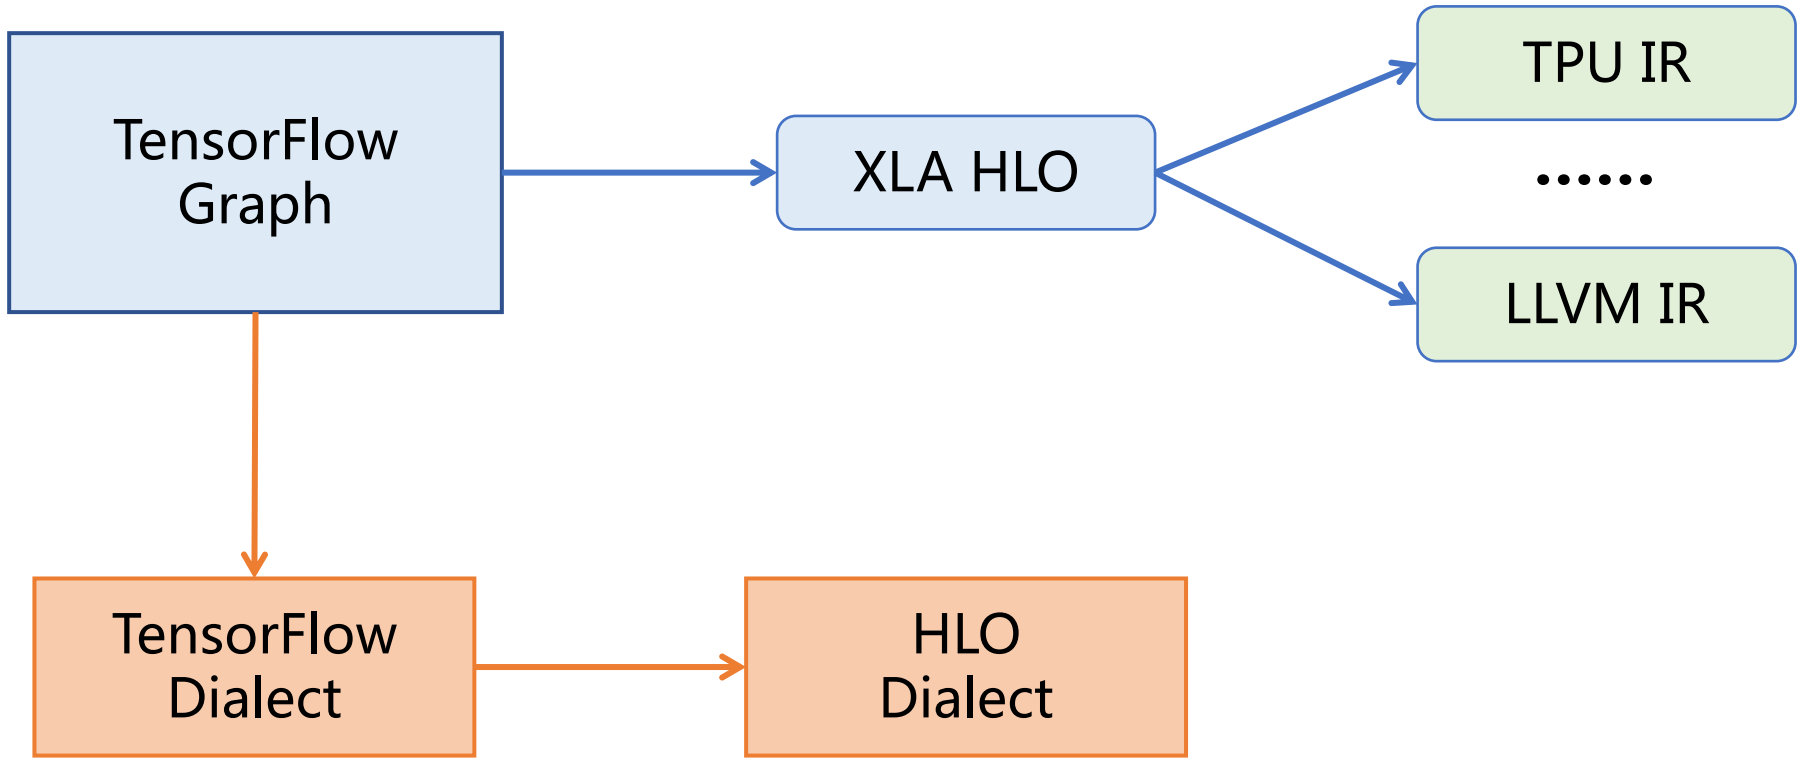

- 组合爆炸，很多组件无法重用
- 各个层次内部优化无法迁移
- 从XLA HLO到LLVM IR跨度太大，实现开销大

MLIR 简介 – MLIR如何解决问题

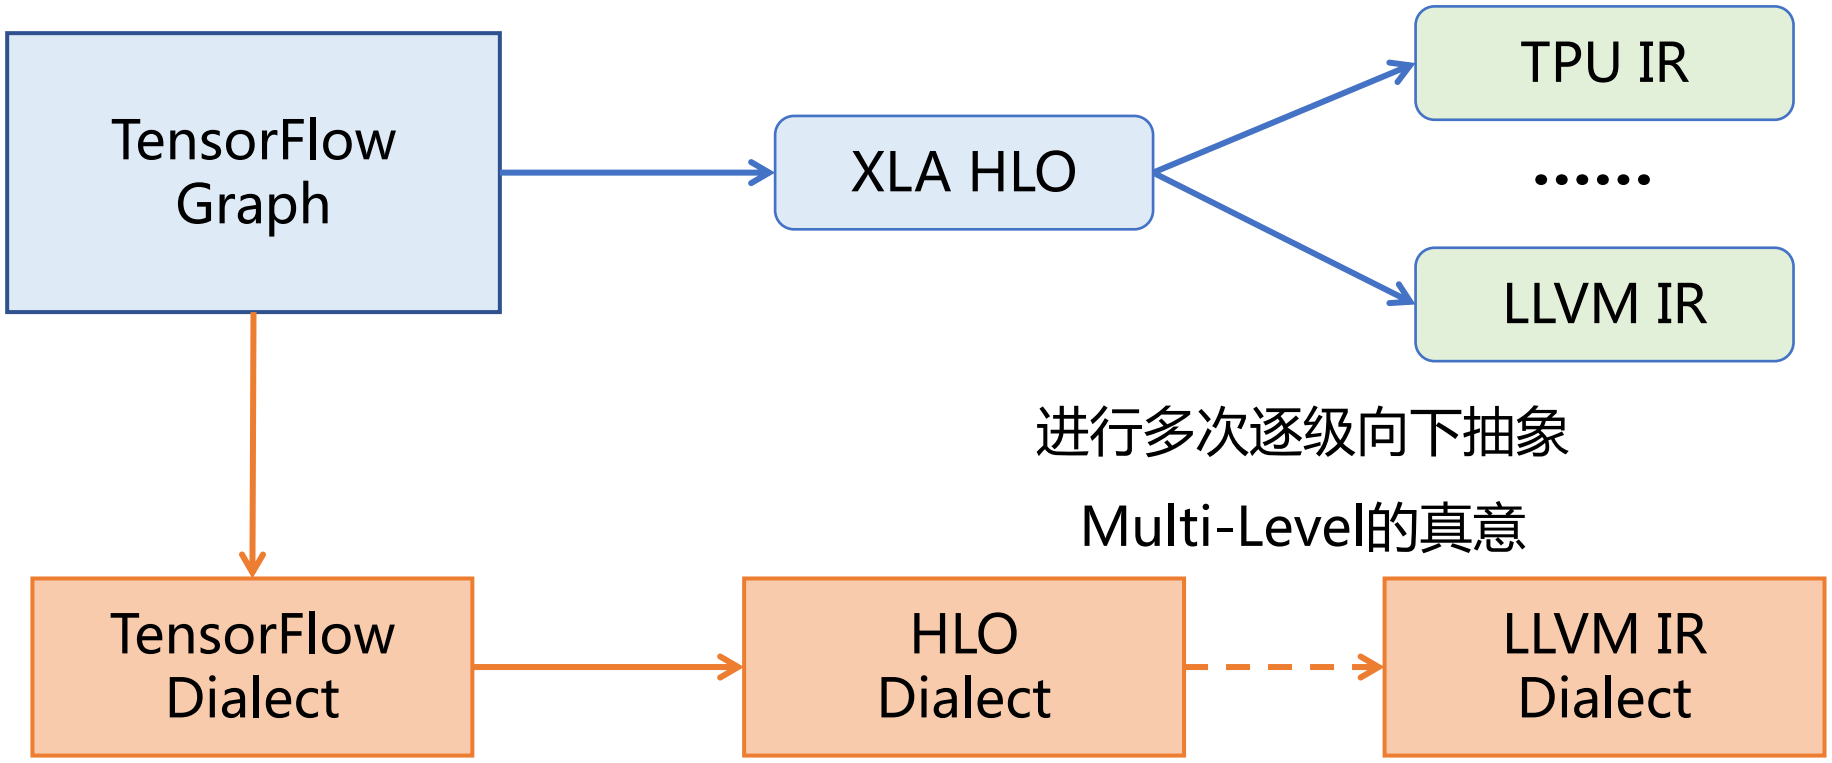

- 组合爆炸，很多组件无法重用
- 各个层次内部优化无法迁移
- 从XLA HLO到LLVM IR跨度太大，实现开销大

MLIR 简介 – MLIR如何解决问题

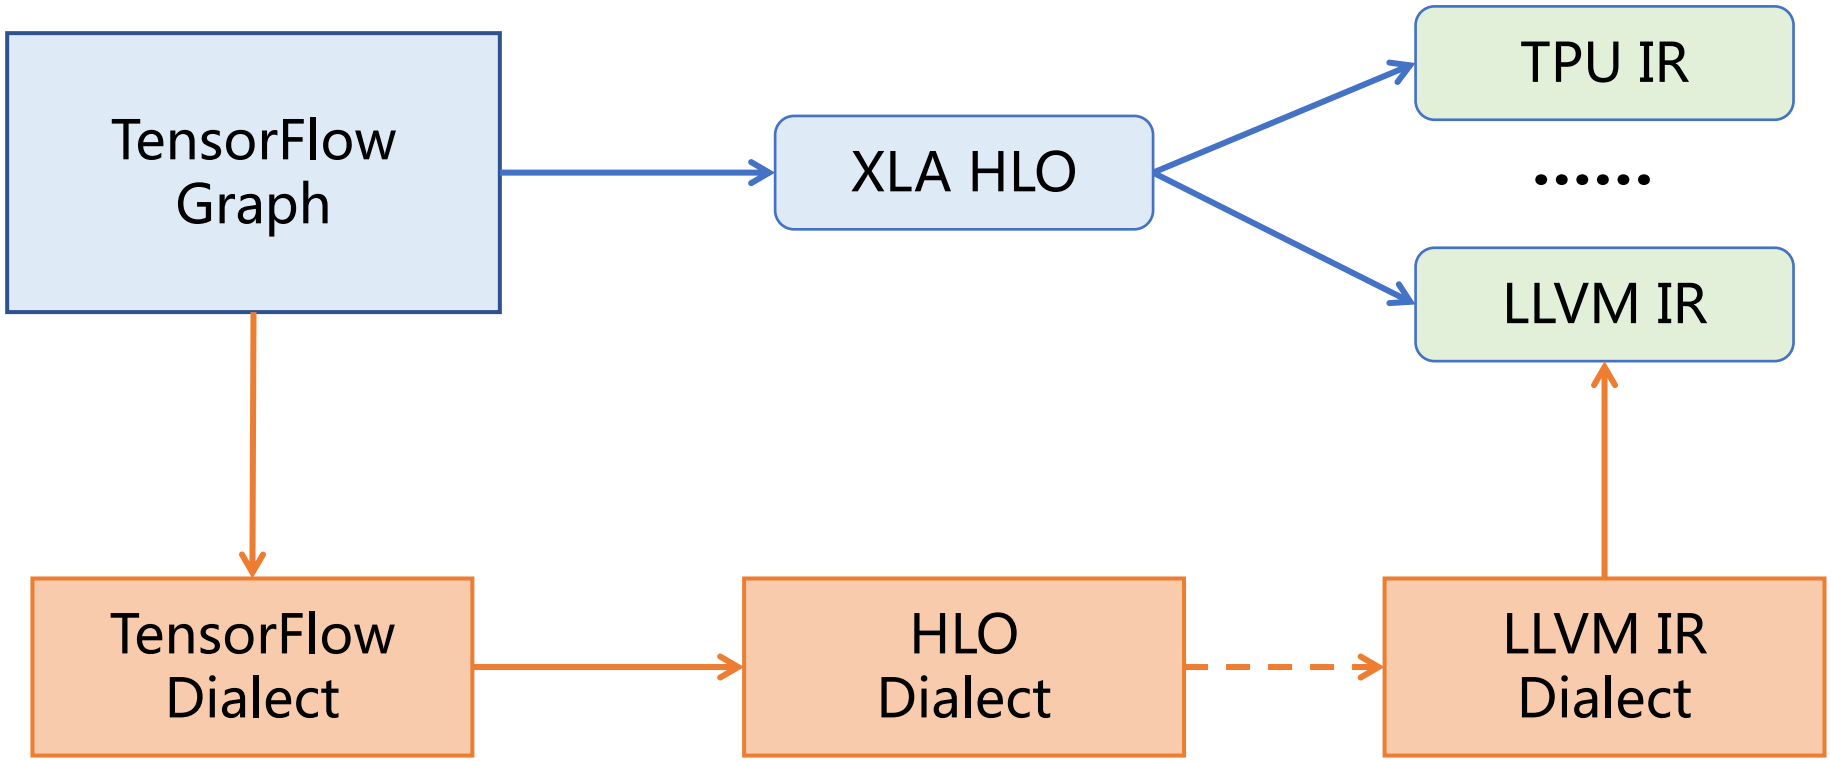

- 组合爆炸，很多组件无法重用
- 各个层次内部优化无法迁移
- 从XLA HLO到LLVM IR跨度太大，实现开销大

MLIR 简介 – MLIR如何解决问题

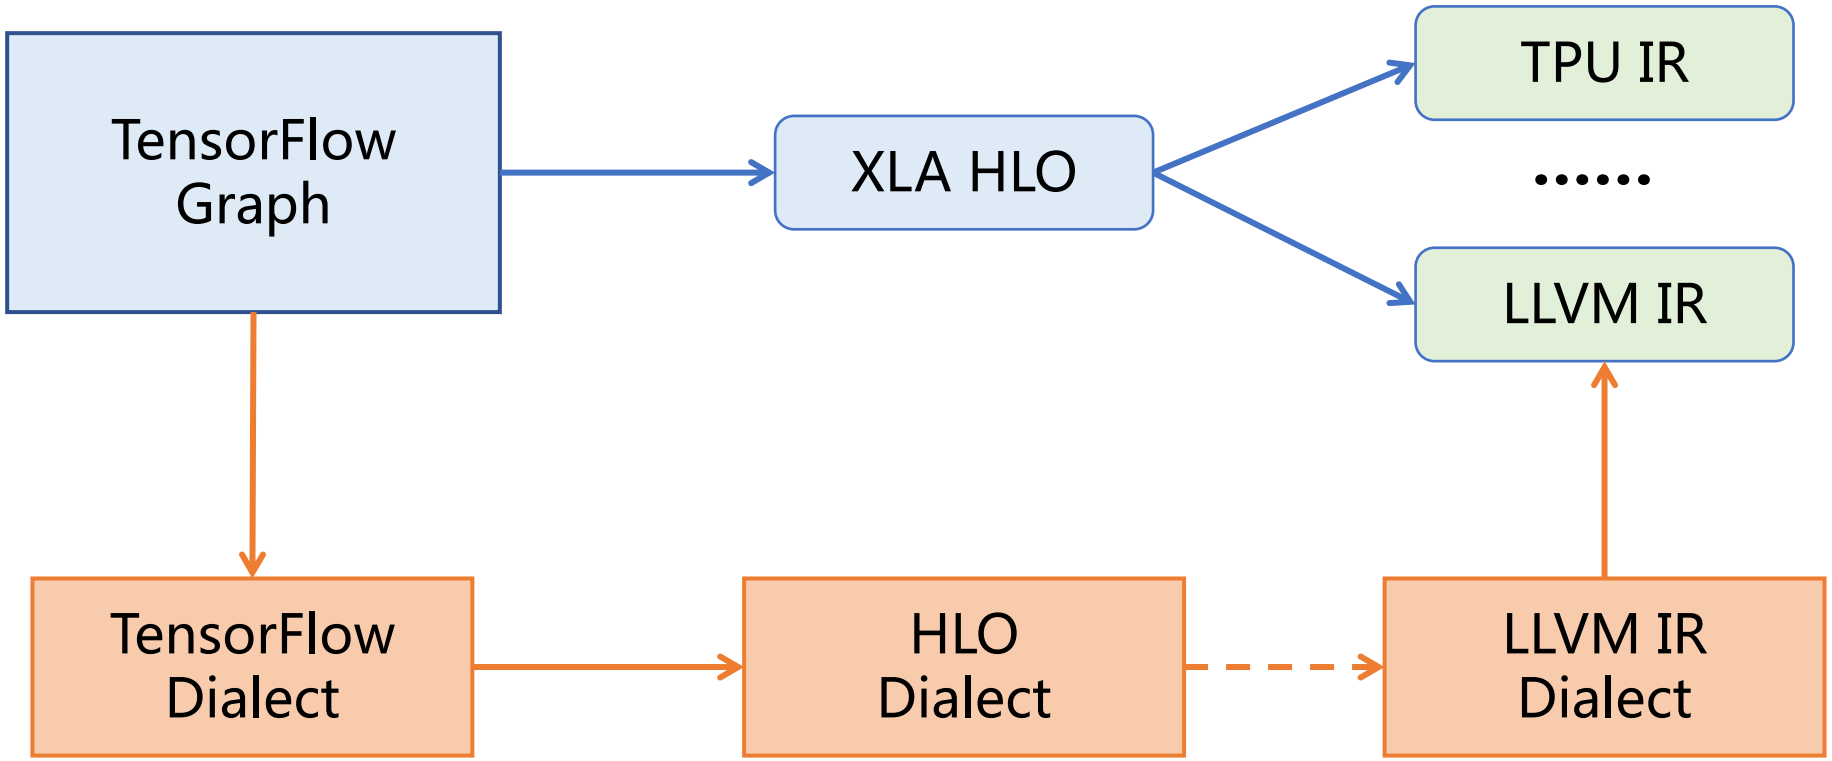

- 组合爆炸，很多组件无法重用
- 各个层次内部优化无法迁移
- 从XLA HLO到LLVM IR跨度太大，实现开销大

语法统一，组件可以重用

共享生态，各个层次可以协调优化

层级之间跨度小，方便实现

2. MLIR 实践 – MLIR 社区工作 | buddy-mlir

MLIR 实践 – MLIR Python Bindings

MLIR 实践 – MLIR Python Bindings

MLIR 实践 – MLIR Python Bindings

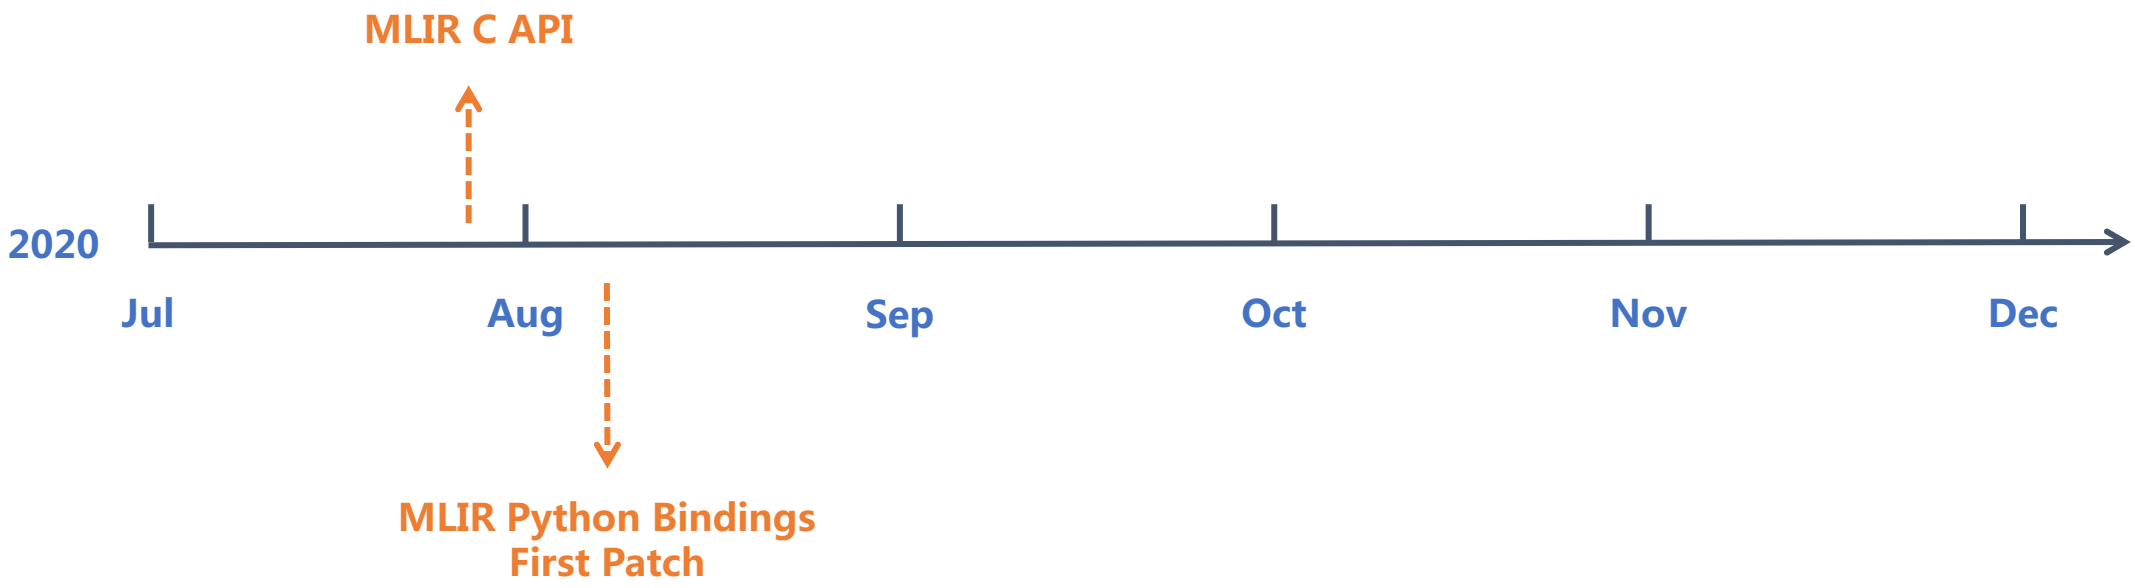

MLIR 实践 – MLIR Python Bindings

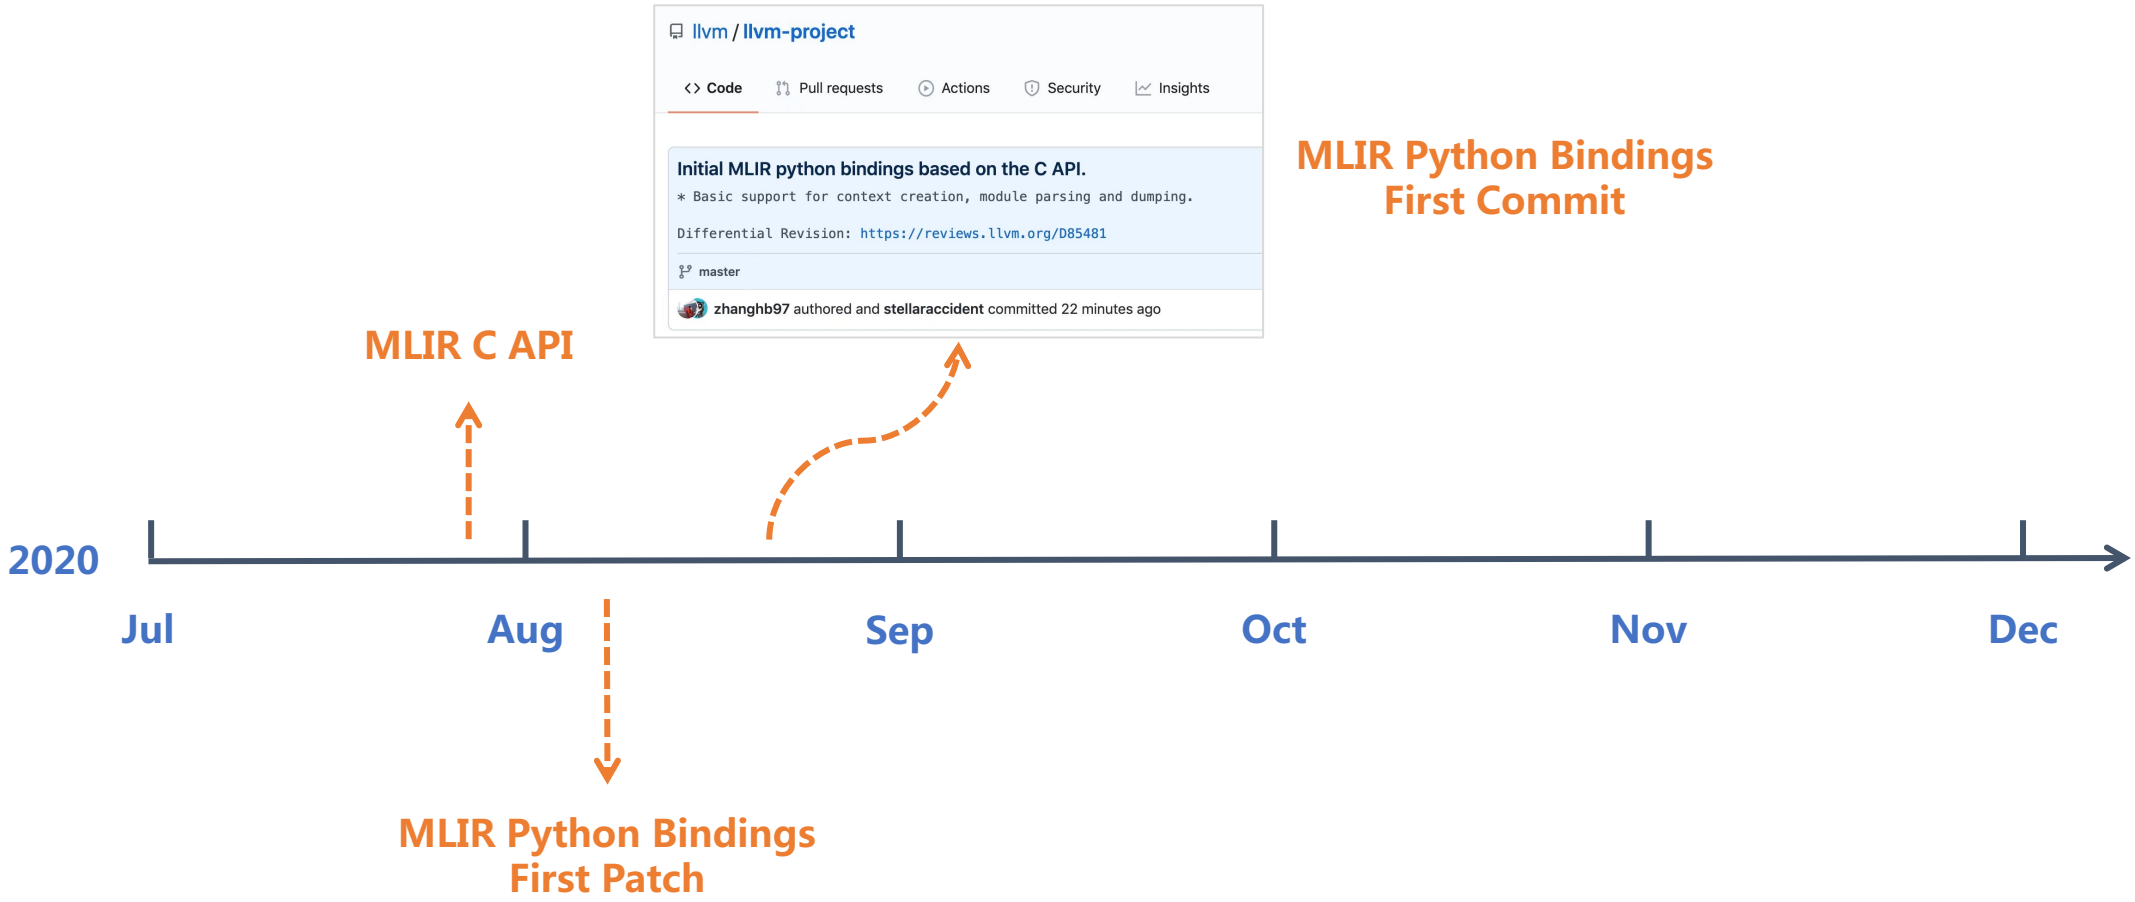

MLIR 实践 – MLIR Python Bindings

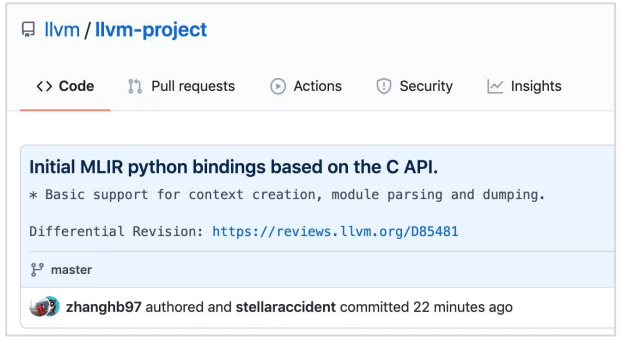

MLIR Python Bindings
First Commit

MLIR C API

2020

Jul | Aug | Sep | Oct | Nov | Dec

MLIR Python Bindings
First Patch

MLIR C API / Python Bindings
Type, Attribute, AffineMap, AffineExpr, etc.

MLIR 实践 – MLIR Python Bindings

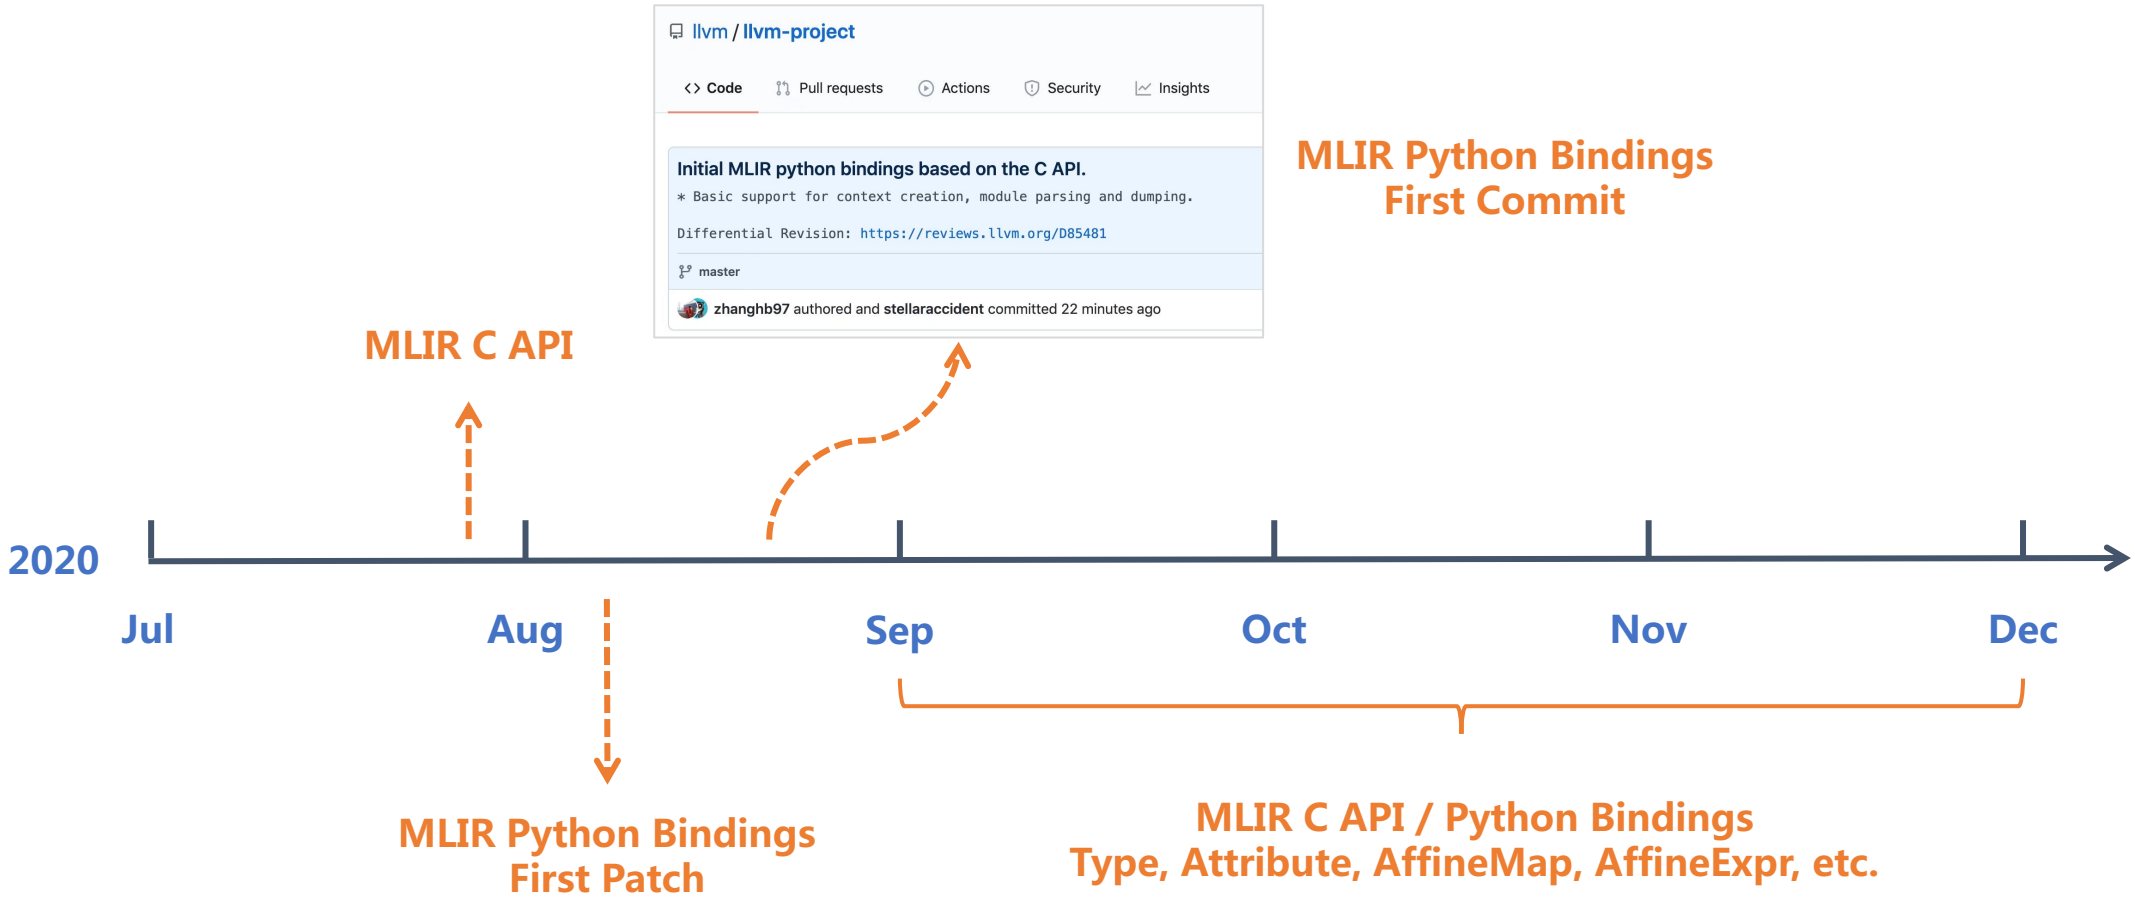

使用/扩展 MLIR Python Bindings 的项目： IREE， MHLO， Torch-MLIR，CIRCT，etc.

MLIR 实践 – MLIR RISC-V Vector Dialect

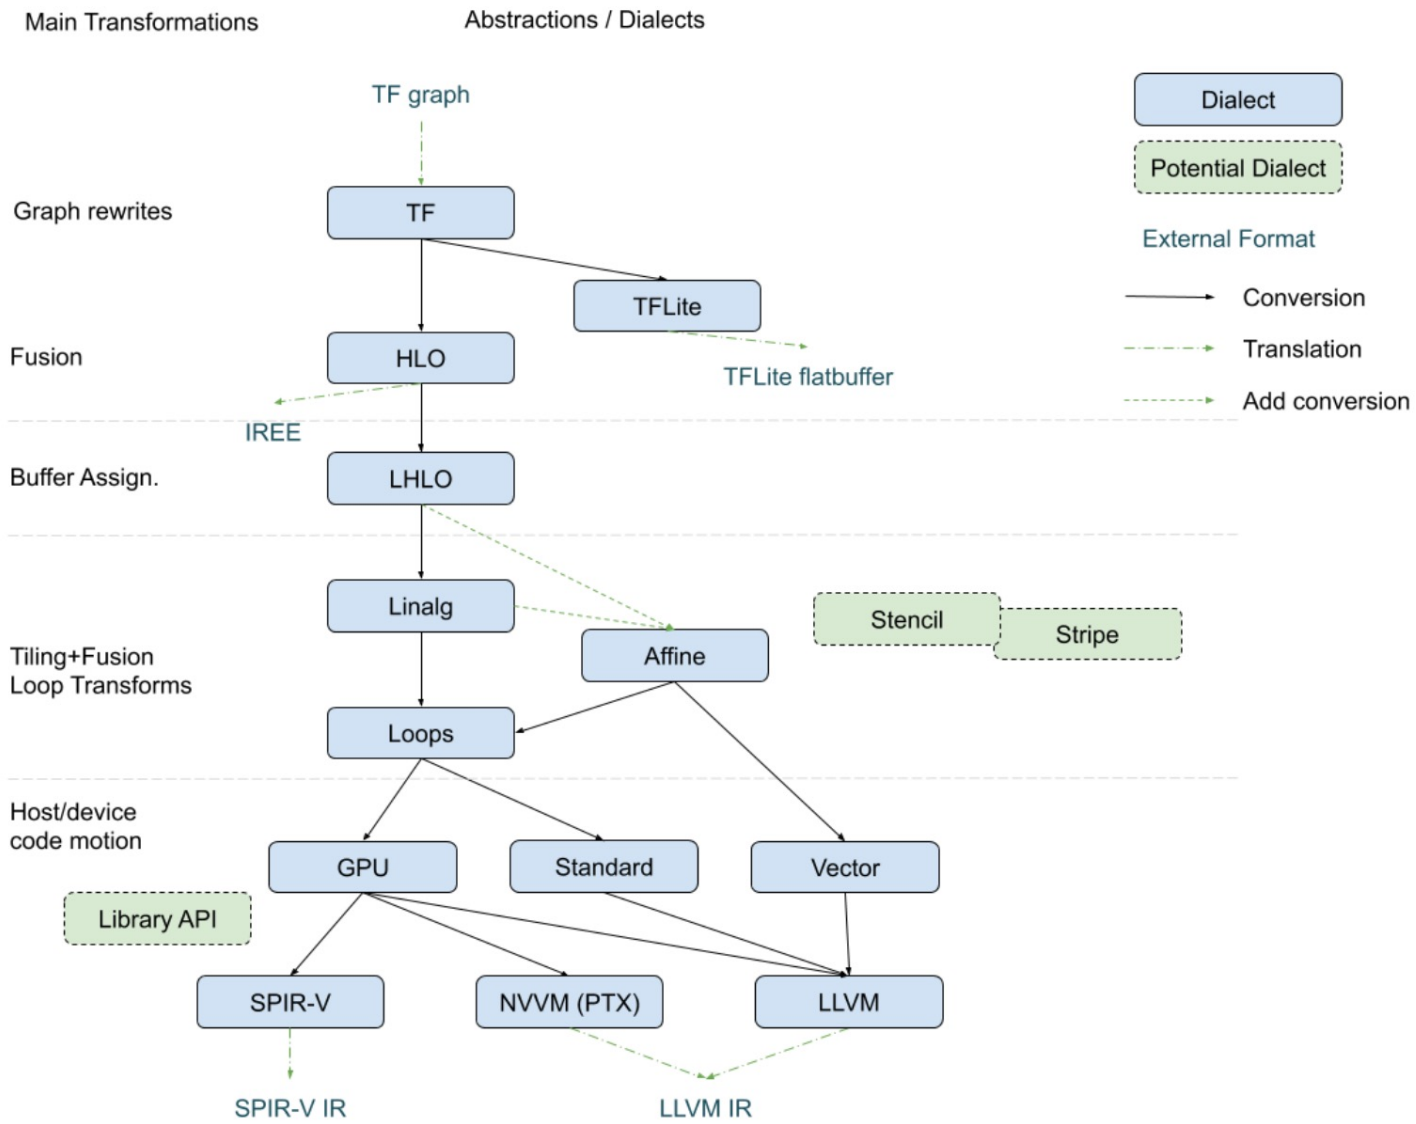

图片来自：https://mlir.llvm.org/docs/Dialects/Vector/

MLIR 实践 – MLIR RISC-V Vector Dialect

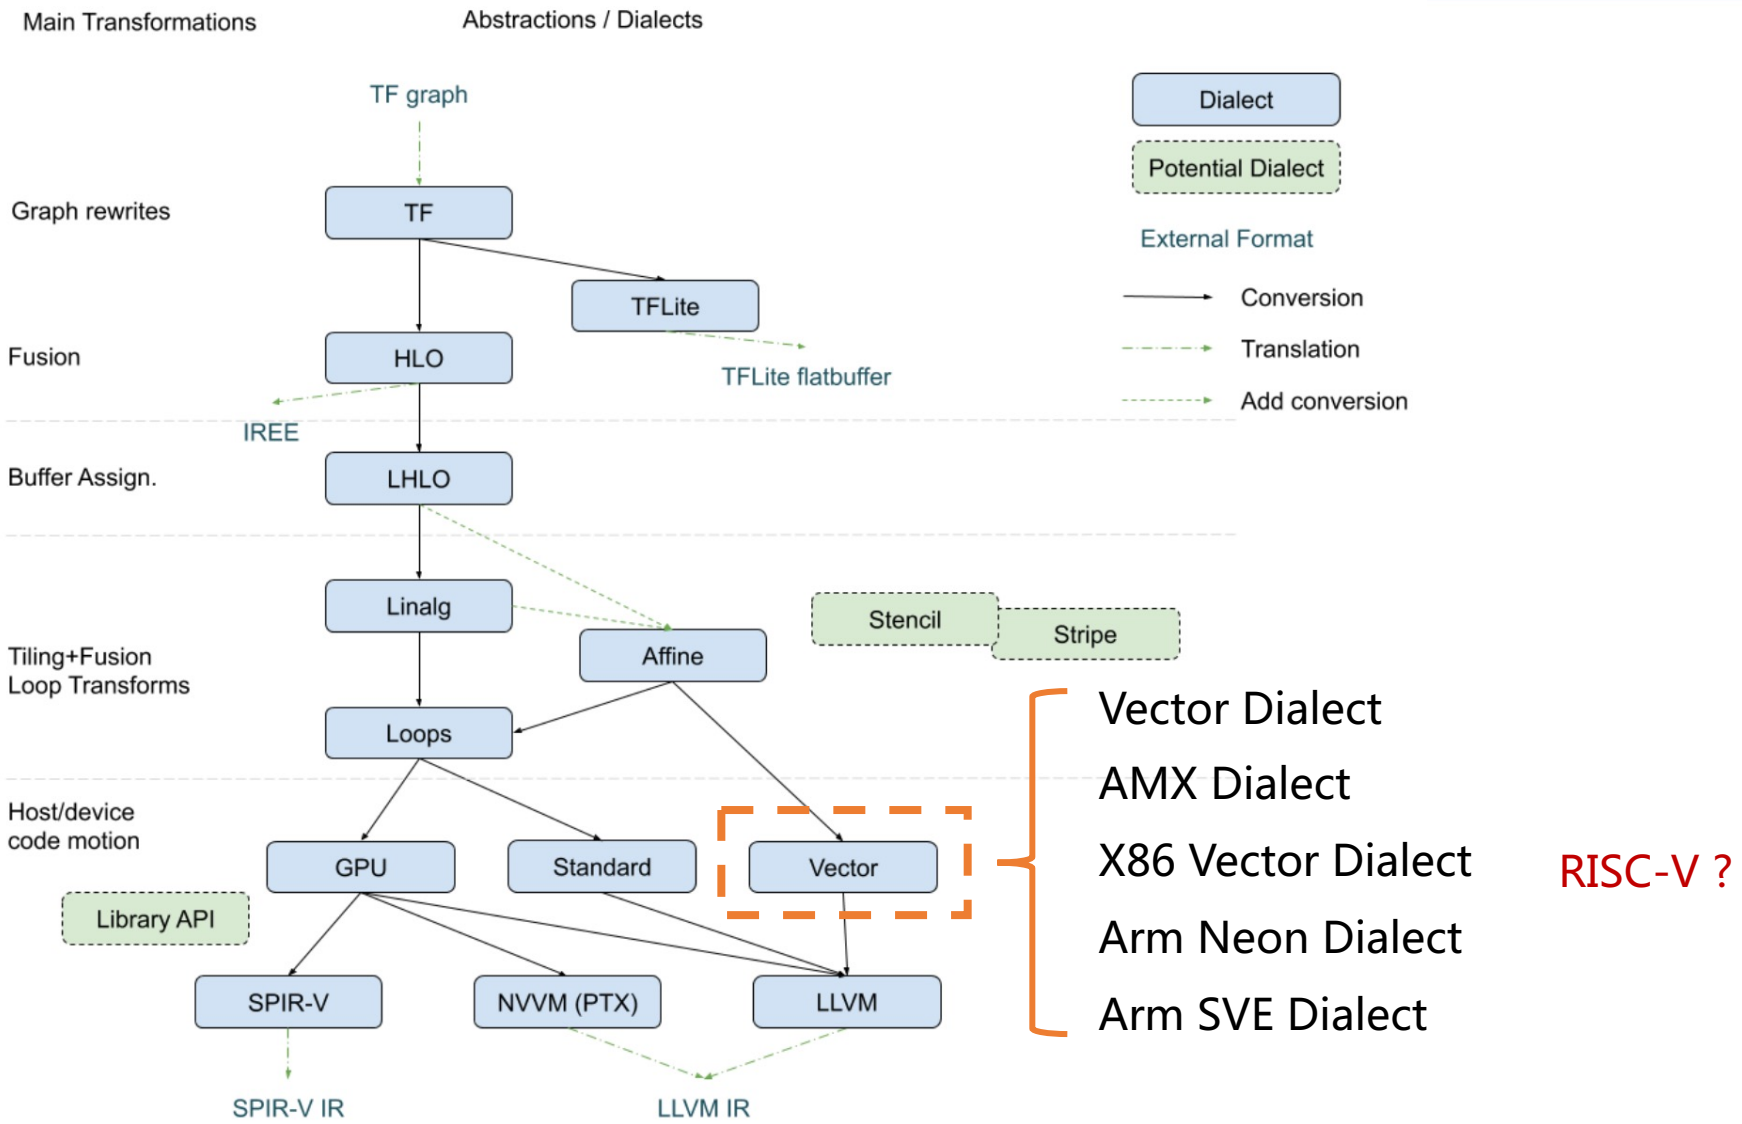

Vector Dialect

AMX Dialect

X86 Vector Dialect

Arm Neon Dialect

Arm SVE Dialect

RISC-V ?

图片来自：https://mlir.llvm.org/docs/Dialects/Vector/

MLIR 实践 – MLIR RISC-V Vector Dialect

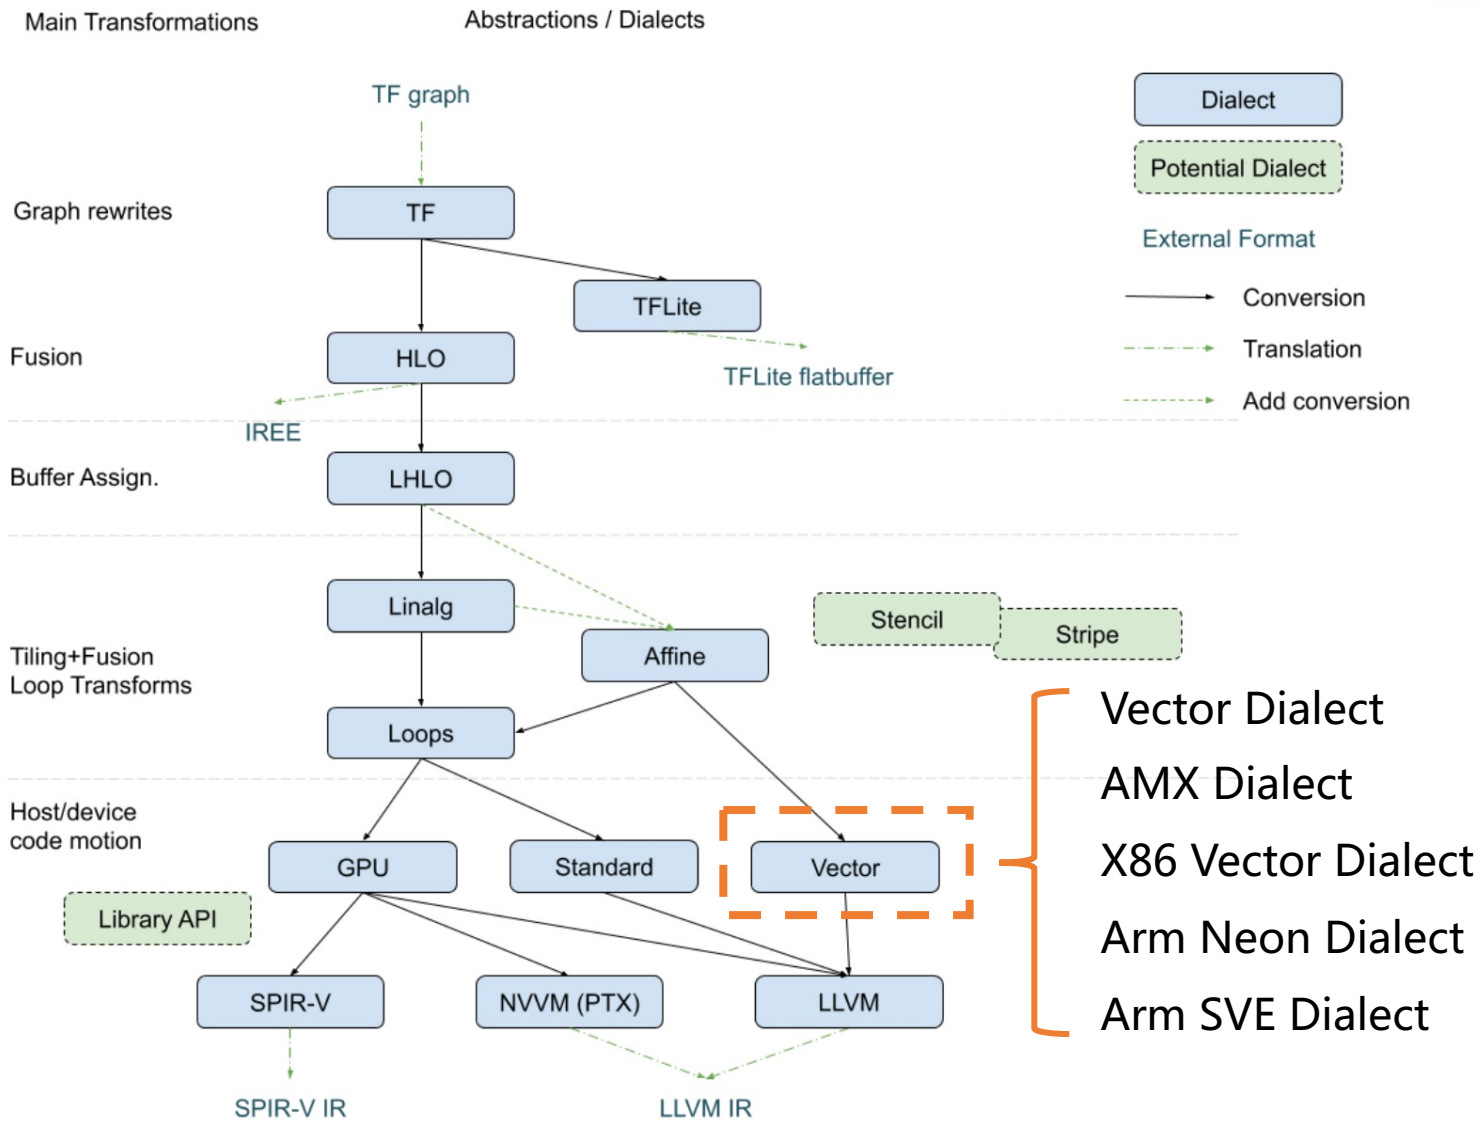

MLIR RISC-V Vector Dialect

- Operation
  - RVV Operation
  - RVV Intrinsic Operation
- Type
  - Scalable Vector Type
- Conversion/Translation
  - RVV Dialect
  - LLVM Dialect
  - LLVM IR

图片来自：https://mlir.llvm.org/docs/Dialects/Vector/

MLIR 实践 – MLIR RISC-V Vector Dialect

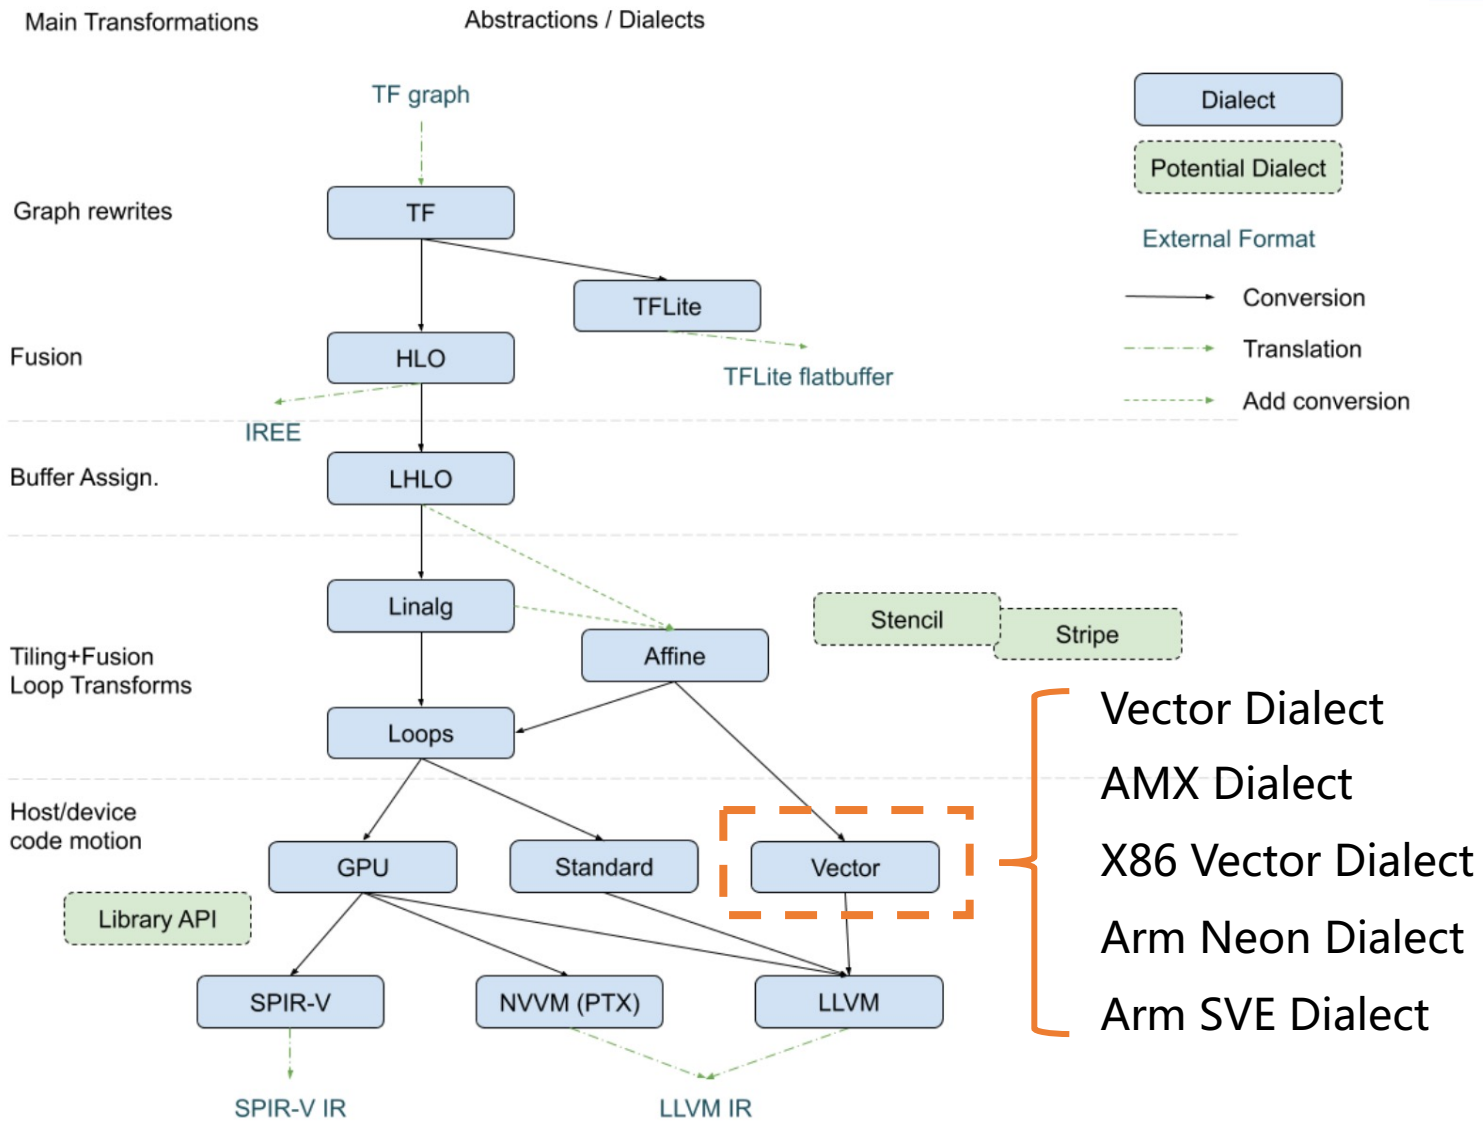

MLIR RISC-V Vector Dialect

- Operation
  - RVV Operation
  - RVV Intrinsic Operation
- Type
  - Scalable Vector Type
- Conversion/Translation
  - RVV Dialect
  - LLVM Dialect
  - LLVM IR

图片来自：https://mlir.llvm.org/docs/Dialects/Vector/

MLIR 实践 – MLIR RISC-V Vector Dialect

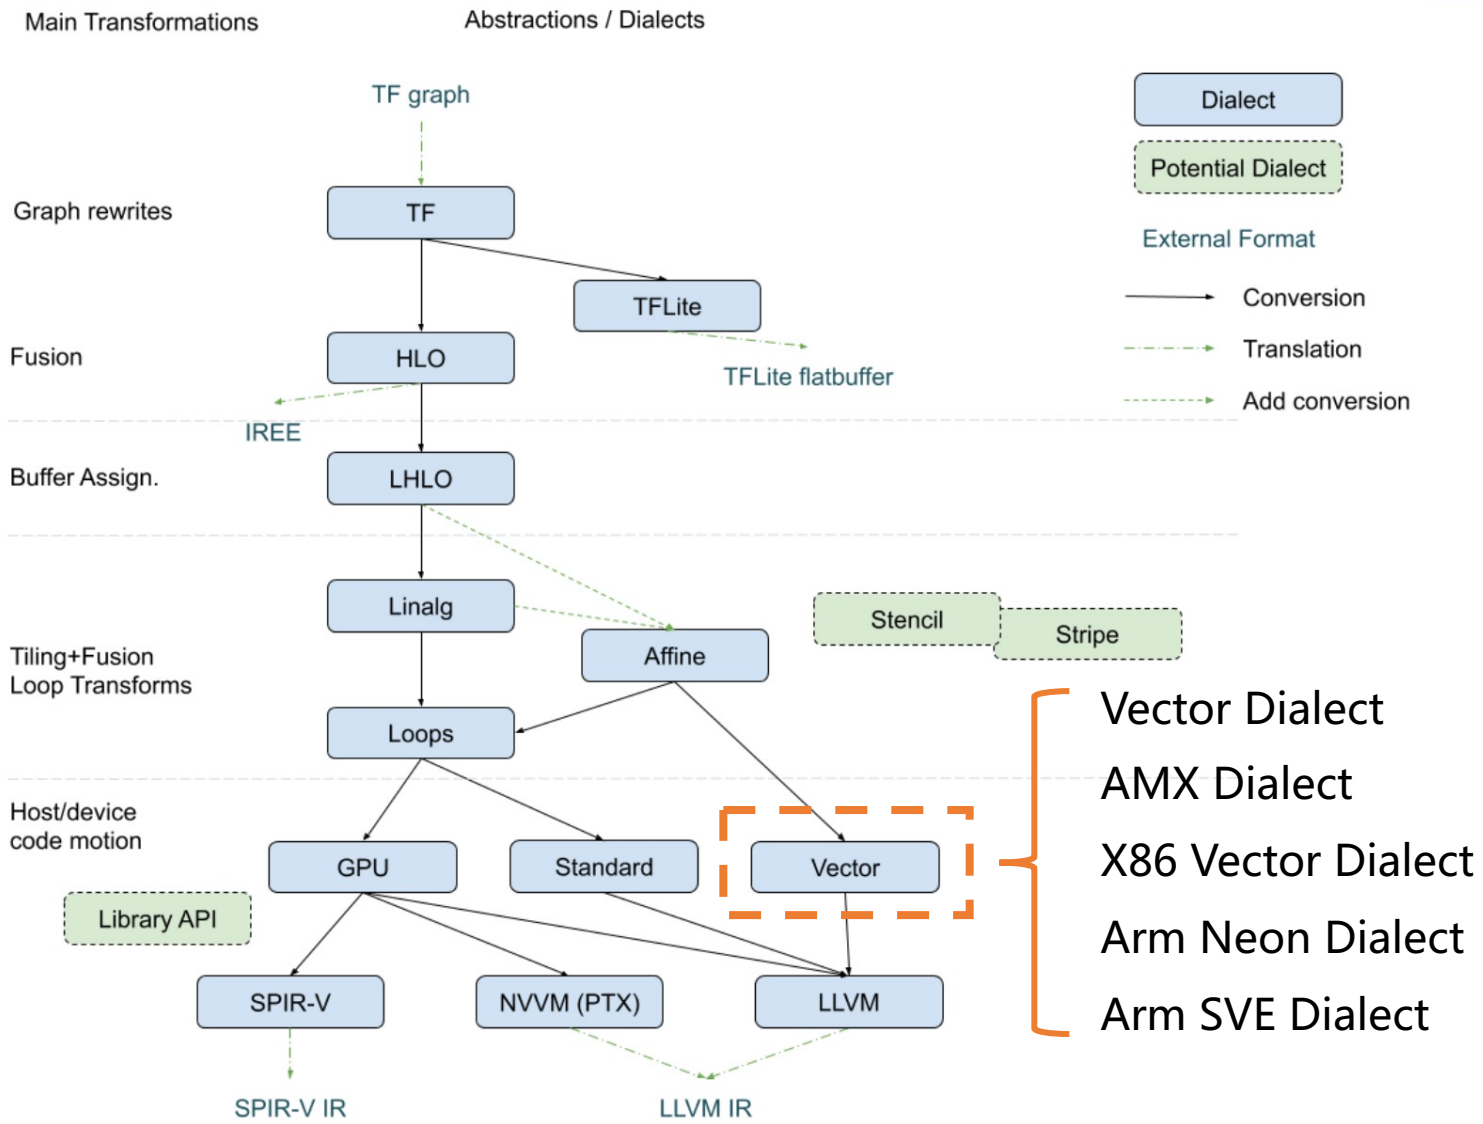

MLIR RISC-V Vector Dialect

- Operation
  - RVV Operation
  - RVV Intrinsic Operation
- Type
  - Scalable Vector Type
- Conversion/Translation
  - RVV Dialect
  - LLVM Dialect
  - LLVM IR

图片来自：https://mlir.llvm.org/docs/Dialects/Vector/

MLIR 实践 – MLIR RISC-V Vector Dialect

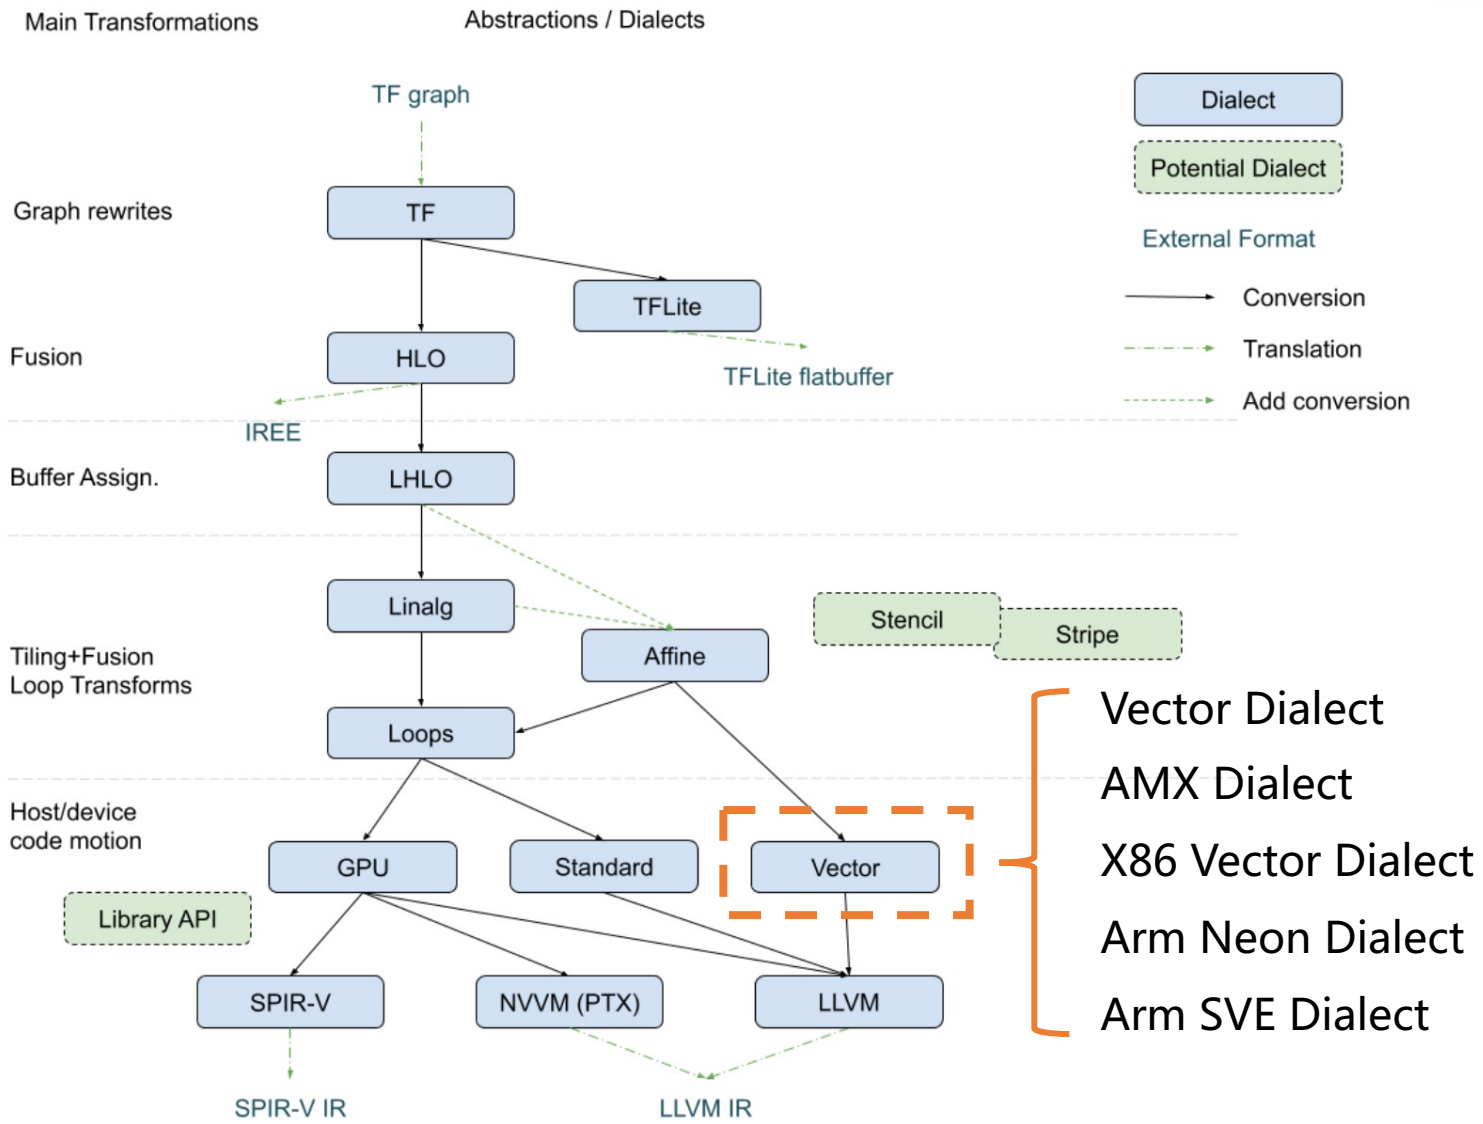

MLIR RISC-V Vector Dialect

- Operation
  - RVV Operation
  - RVV Intrinsic Operation
- Type
  - Scalable Vector Type
- Conversion/Translation
  - RVV Dialect
  - LLVM Dialect
  - LLVM IR

图片来自：https://mlir.llvm.org/docs/Dialects/Vector/

MLIR 实践 – Buddy MLIR

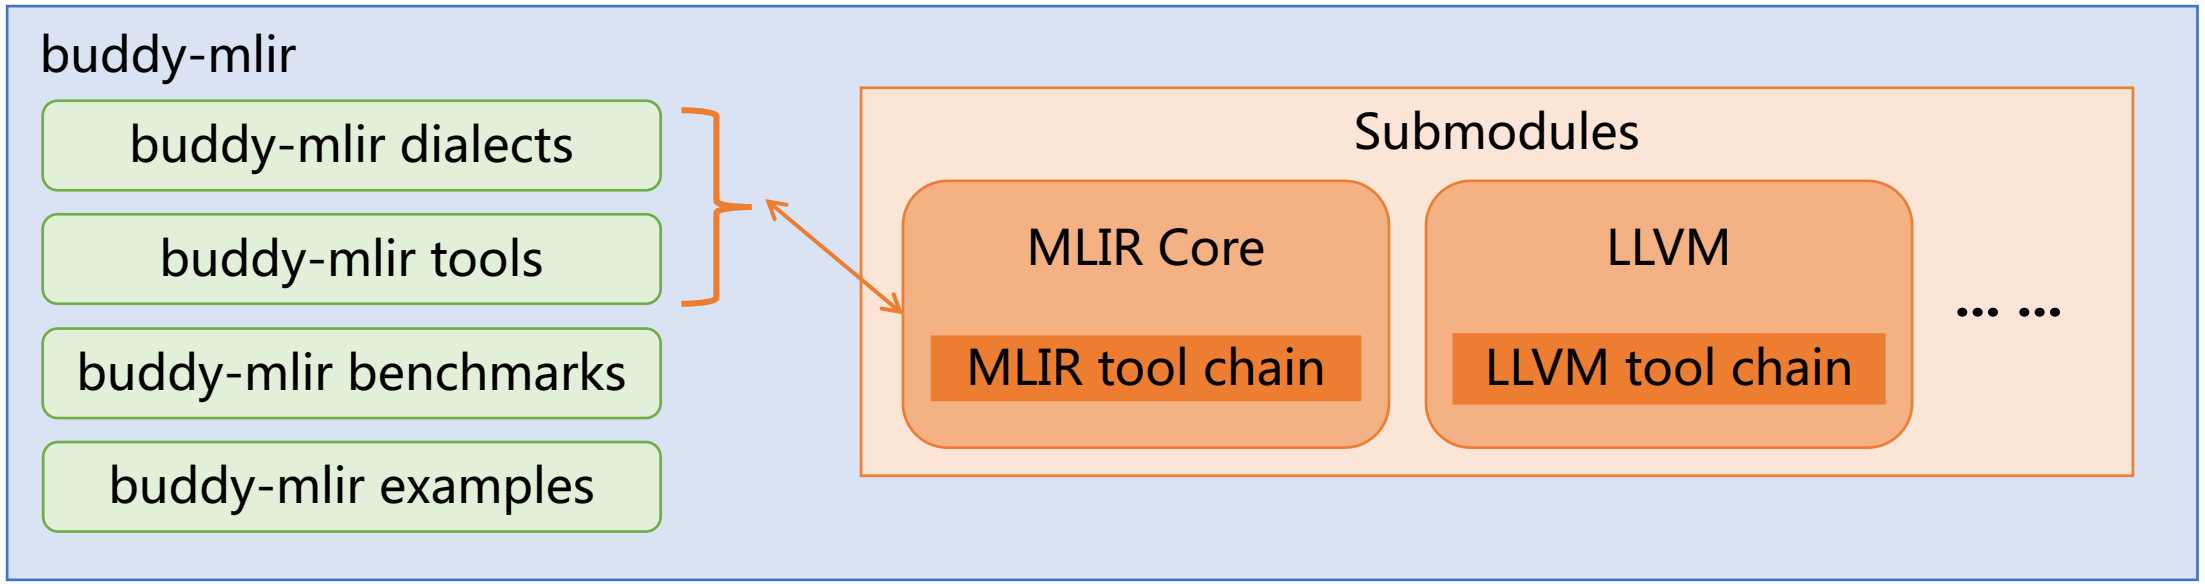

THE LINUX FOUNDATION

RISC-V | Vector Programming | Instruction Set Architecture

RISC-V Mentorship: MLIR Convolution Vectorization

Mentors

Mentees

MLIR 实践 – Buddy MLIR

边缘检测（Sobel Kernel）

原始图片	3x3 Kernel	5x5 Kernel	7x7 Kernel	9x9 Kernel
1024 x 1024	OpenCV: 3.31541 s	OpenCV: 9.55226 s	OpenCV: 21.8928 s	OpenCV: 32.3142 s
执行 1000 次	**conv-opt: 1.12211 s**	**conv-opt: 2.48518 s**	**conv-opt: 4.47707 s**	**conv-opt: 7.58269 s**

卷积向量化工具 conv-opt

buddy-mlir：https://github.com/buddy-compiler/buddy-mlir

3. MLIR 思考 – 基于 MLIR 的深度学习框架

MLIR 思考 – 基于 MLIR 的深度学习框架

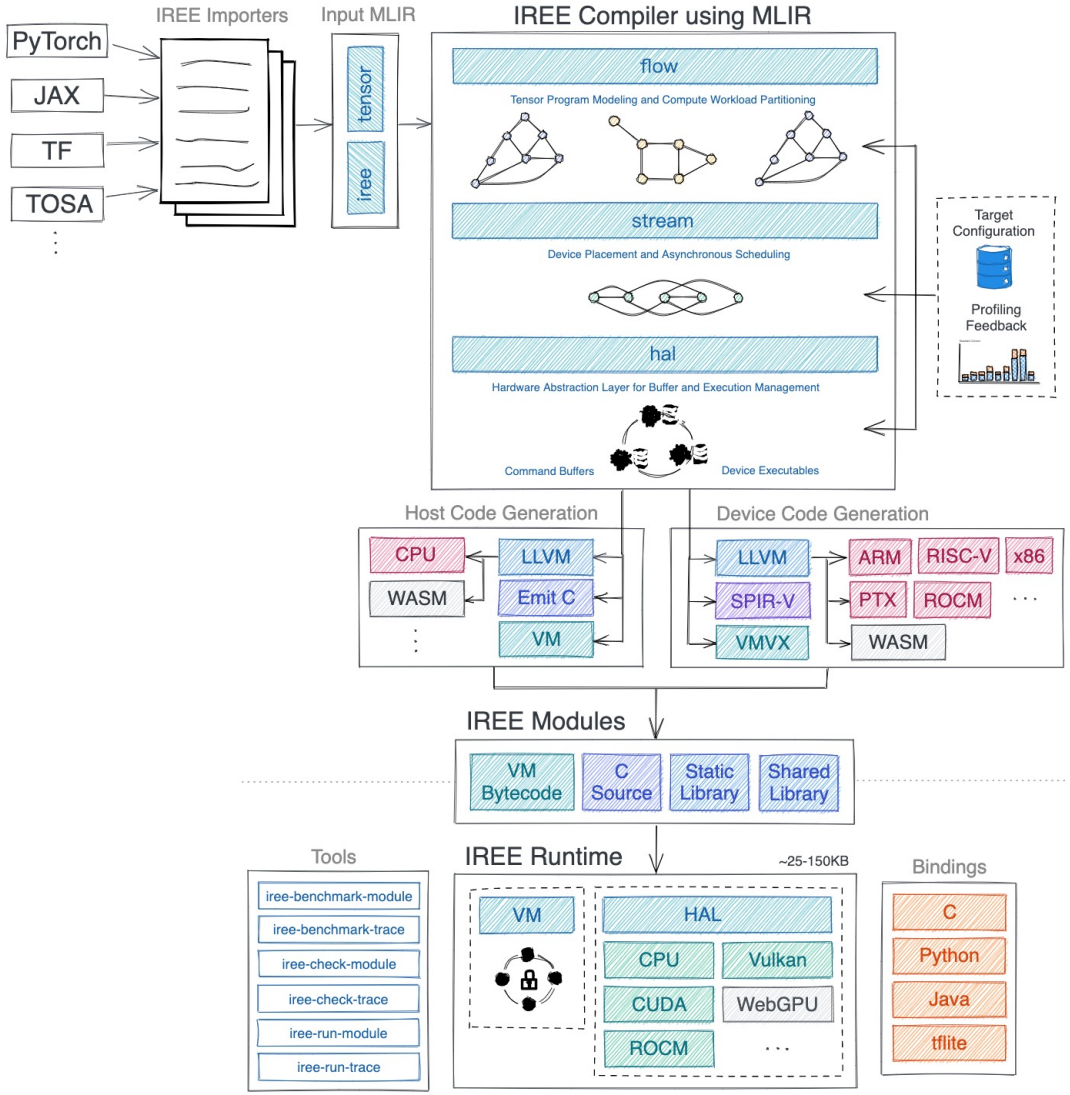

IREE（IR Execution Environment）

机器学习程序部署框架

图片来自：https://mlir.llvm.org/docs/Dialects/Vector/

MLIR 思考 – 基于 MLIR 的深度学习框架

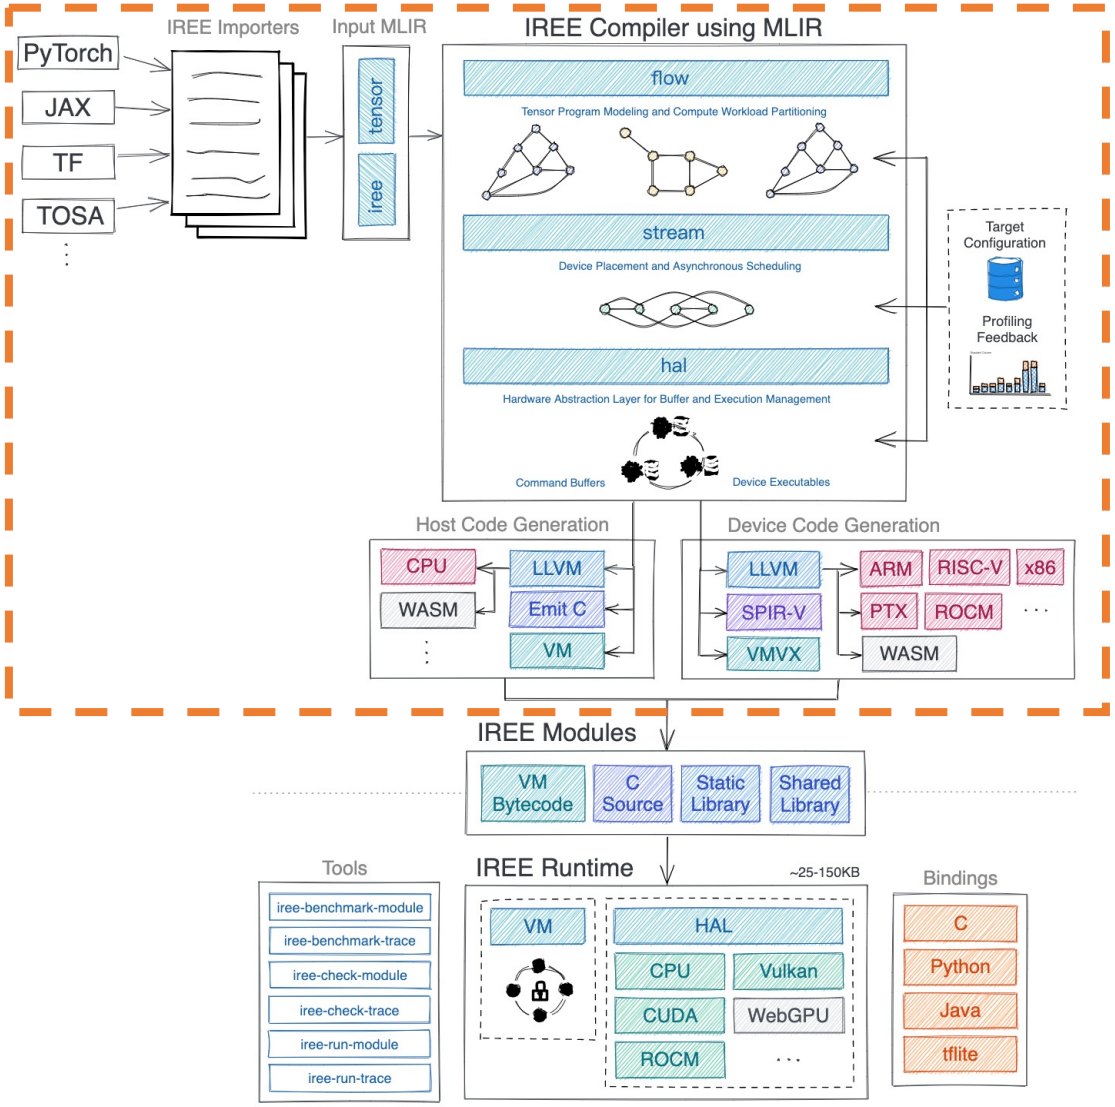

IREE（IR Execution Environment）

机器学习程序部署框架

从模型翻译到 MLIR
将程序分成 host 和 device
生成中间产物（VM FlatBuffers，C file，etc.）

图片来自：https://mlir.llvm.org/docs/Dialects/Vector/

MLIR 思考 – 基于 MLIR 的深度学习框架

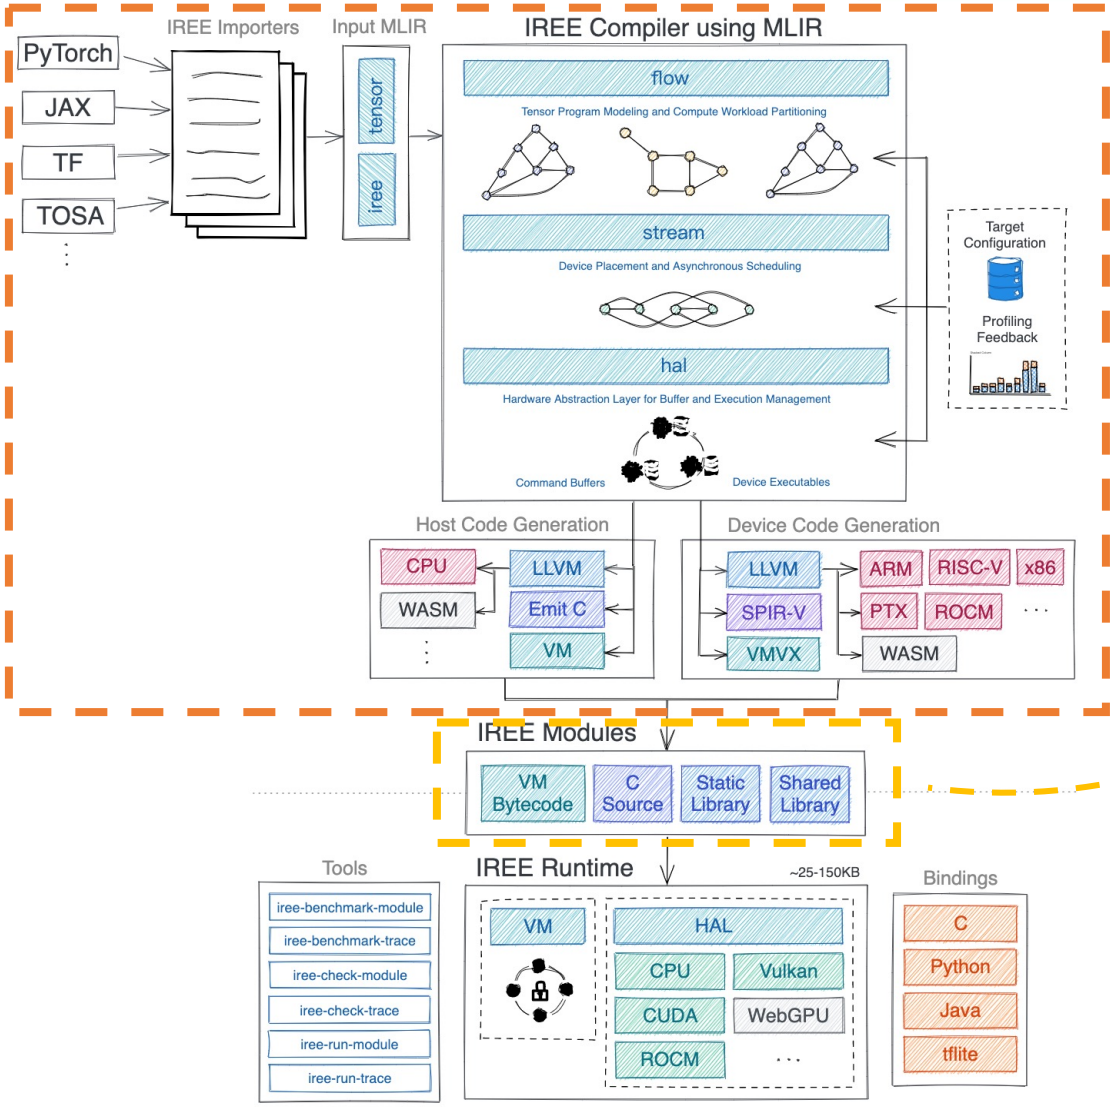

IREE（IR Execution Environment）

机器学习程序部署框架

从模型翻译到 MLIR
将程序分成 host 和 device
生成中间产物（VM FlatBuffers，C file，etc.）

将 host 和 device 端代码生成可执行程序/库
和 IREE 硬件抽象层（HAL）链接

图片来自：https://mlir.llvm.org/docs/Dialects/Vector/

MLIR 思考 – 基于 MLIR 的深度学习框架

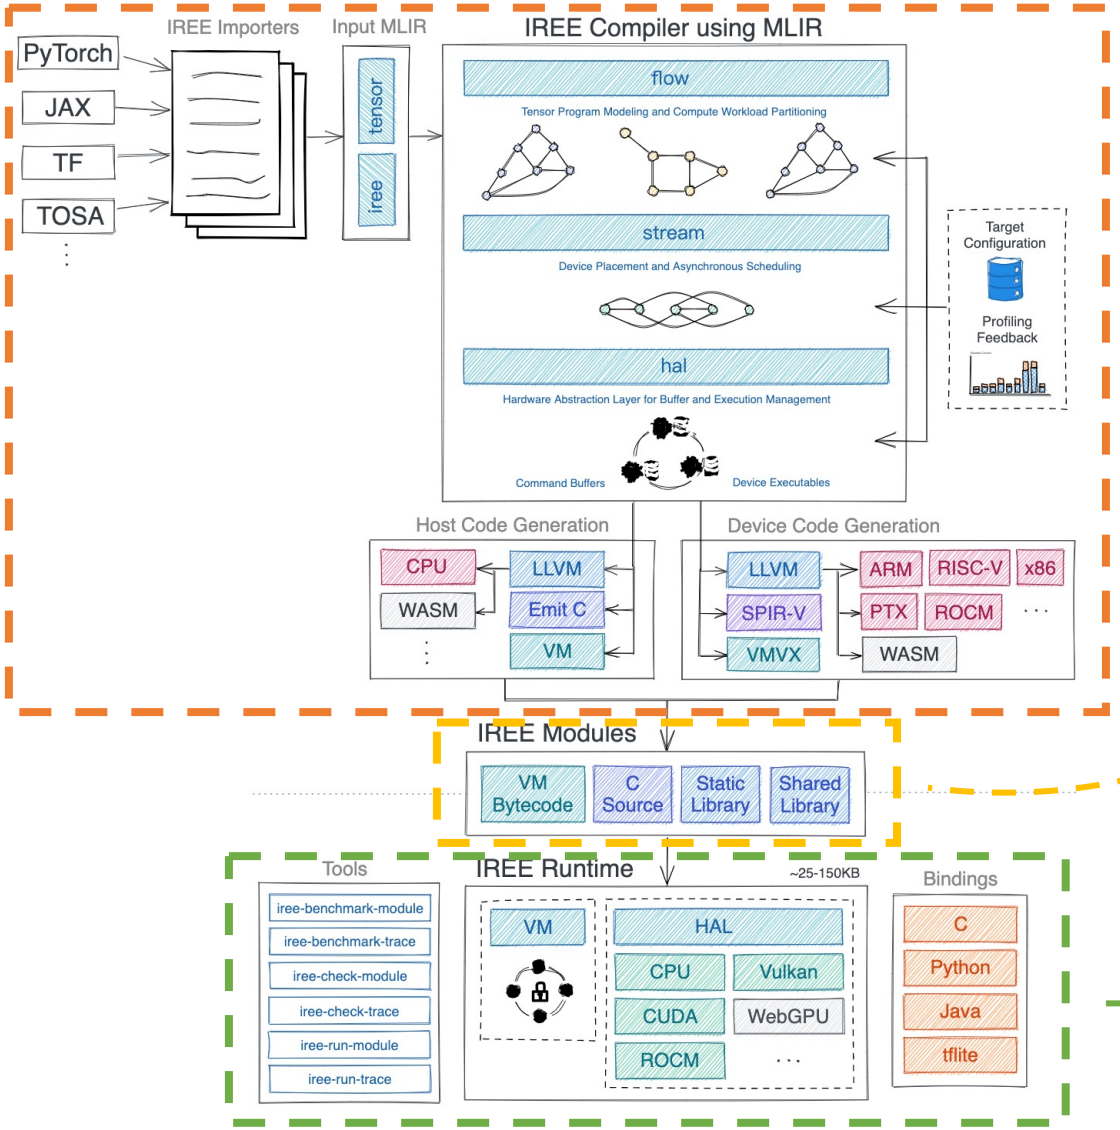

IREE（IR Execution Environment）

机器学习程序部署框架

从模型翻译到 MLIR
将程序分成 host 和 device
生成中间产物（VM FlatBuffers，C file，etc.）

将 host 和 device 端代码生成可执行程序/库
和 IREE 硬件抽象层（HAL）链接

IREE 字节码虚拟机（Bytecode VM）
硬件抽象层接口（HAL API）和各种硬件抽象
通用接口以及各种语言/框架的绑定

图片来自：https://mlir.llvm.org/docs/Dialects/Vector/

MLIR 思考 – 基于 MLIR 的深度学习框架

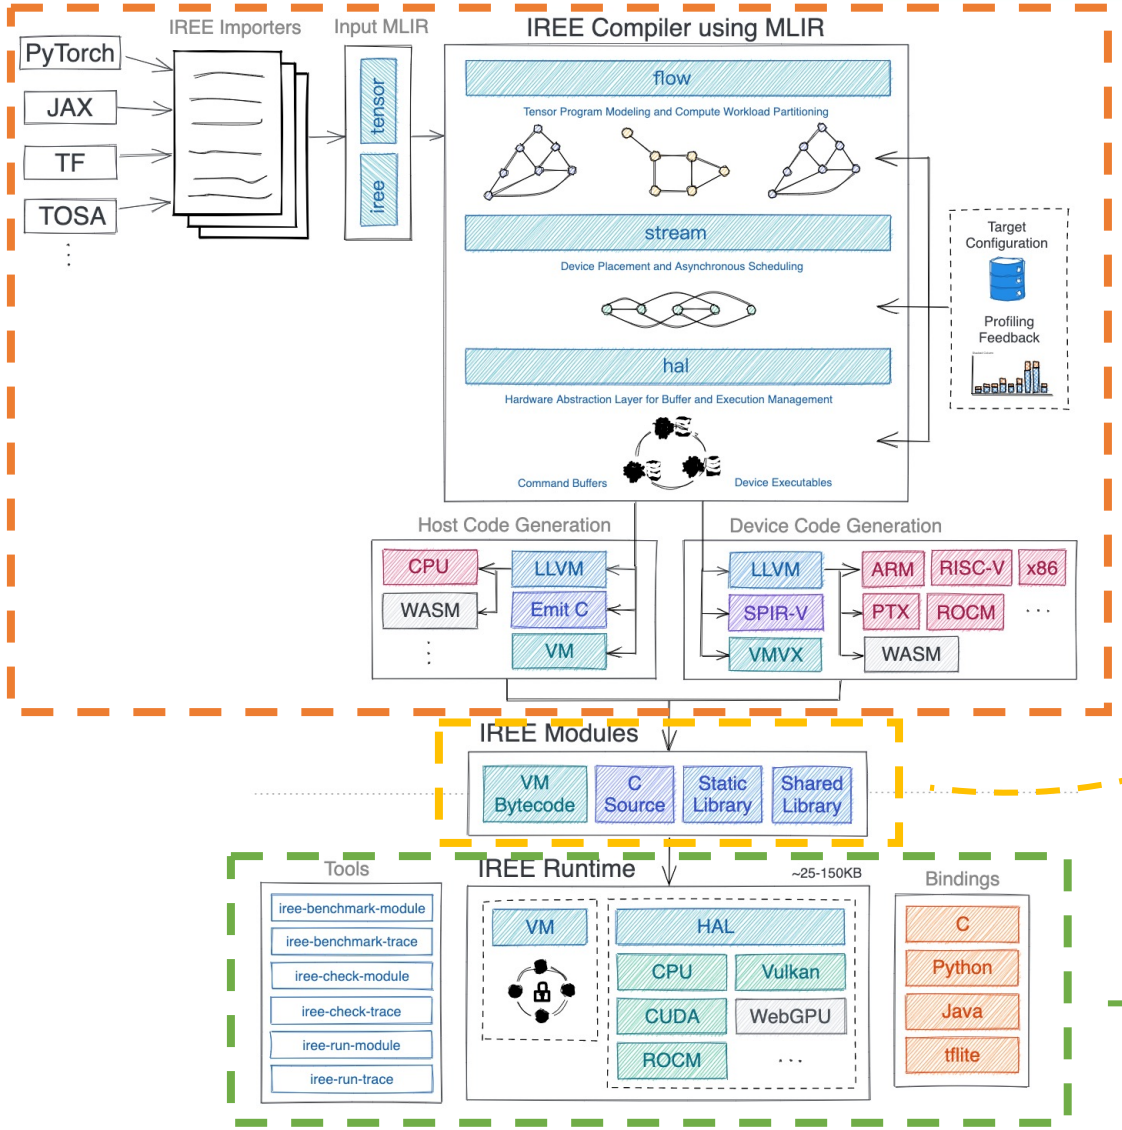

IREE（IR Execution Environment）

机器学习程序部署框架

从模型翻译到 MLIR
将程序分成 host 和 device
生成中间产物（VM FlatBuffers，C file，etc.）

如何在多层 IR 中更好的应用编译技术

将 host 和 device 端代码生成可执行程序/库
和 IREE 硬件抽象层（HAL）链接

IREE 字节码虚拟机（Bytecode VM）
硬件抽象层接口（HAL API）和各种硬件抽象
通用接口以及各种语言/框架的绑定

图片来自：https://mlir.llvm.org/docs/Dialects/Vector/

MLIR 思考 – 基于 MLIR 的深度学习框架

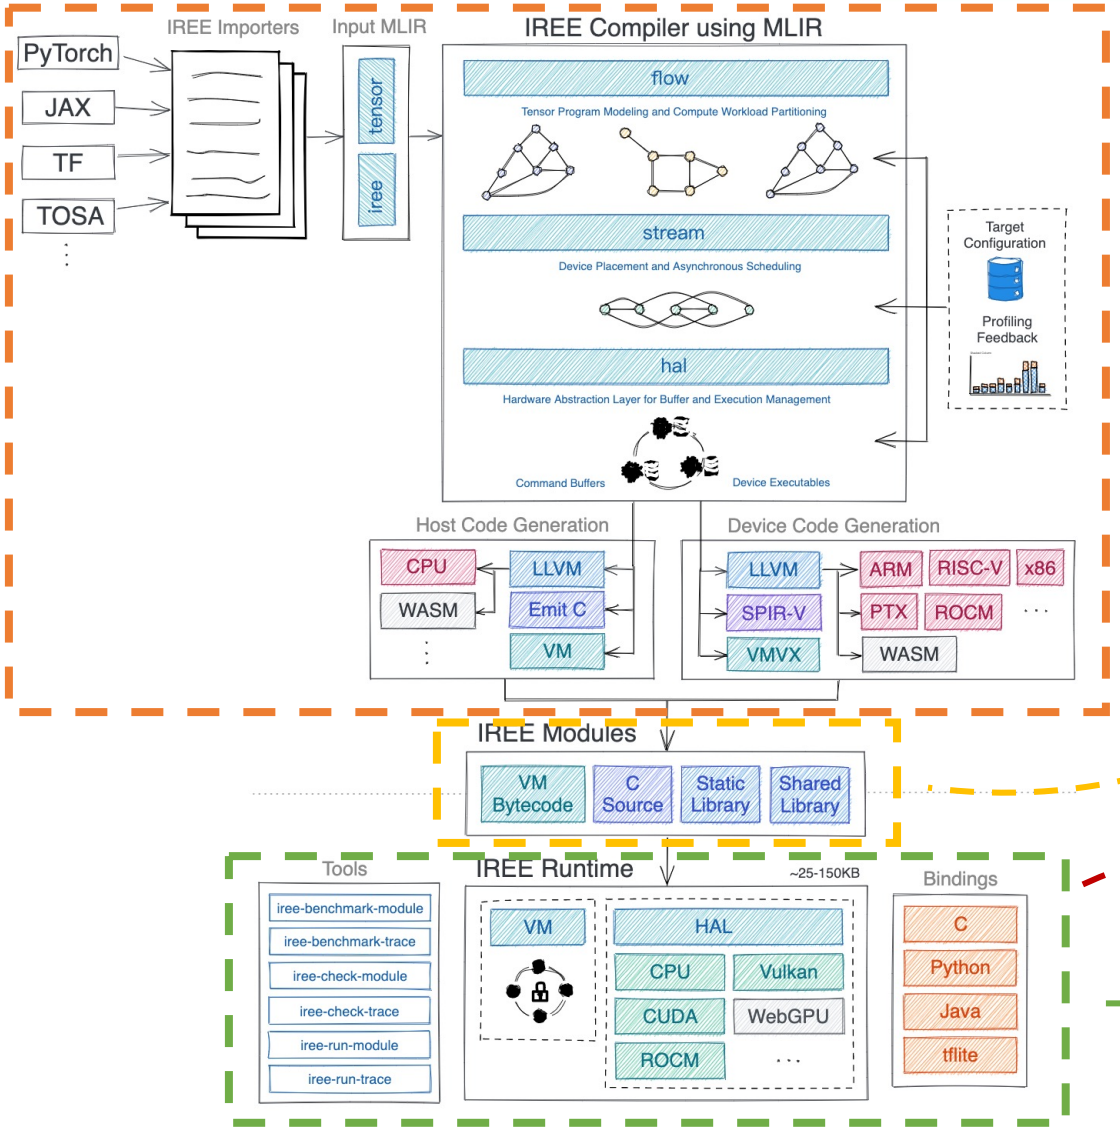

IREE（IR Execution Environment）

机器学习程序部署框架

从模型翻译到 MLIR
将程序分成 host 和 device
生成中间产物（VM FlatBuffers，C file，etc.）

如何在多层 IR 中更好的应用编译技术

将 host 和 device 端代码生成可执行程序/库
和 IREE 硬件抽象层（HAL）链接

在 DSA 百花齐放的时代，如何做好统一的硬件抽象层

IREE 字节码虚拟机（Bytecode VM）
硬件抽象层接口（HAL API）和各种硬件抽象
通用接口以及各种语言/框架的绑定

图片来自：https://mlir.llvm.org/docs/Dialects/Vector/

ISCAS 中国科学院软件研究所 Institute of Software Chinese Academy of Sciences

智能软件研究中心 Intelligent Software Research Center

Q & A